



GGUF格式详解



mingming

保持理智, 相信未来

关注她

13 人赞同了该文章 >

GGUF格式⁺是用于存储大型模型预训练结果的，相较于Hugging Face⁺和torch的bin文件，它采用了紧凑的二进制编码格式、优化的数据结构以及**内存映射**⁺等技术，提供了更高效的数据存储和访问方式。

内存映射(mmap) 指允许直接从磁盘映射数据到内存地址空间，加快了数据的加载速度。这样，数据可以在不实际加载整个文件的情况下被访问，特别是对于大型模型非常有效

GGUF文件主要包含三部分包括文件头、元数据键值对和**张量信息**⁺，具体一点包含一下几个部分。

- **文件头 (Header):** 包含用于识别文件类型和版本的基本信息。
 - Magic Number : 一个特定的数字或字符序列，用于标识文件格式。
 - Version : 文件格式的版本号，指明了文件遵循的具体规范或标准。
- **元数据键值对 (Metadata Key-Value Pairs):** 存储关于模型的额外信息，如作者、训练信息、模型描述等。
 - Key : 一个字符串，标识元数据的名称。
 - Value Type : 数据类型，指明值的格式（如整数、浮点数、字符串等）。
 - Value : 具体的元数据内容。
- **张量计数 (Tensor Count):** 标识文件中包含的张量 (Tensor) 数量。
 - Count : 一个整数，表示文件中张量的总数。
- **张量信息 (Tensor Info):** 描述每个张量的具体信息，包括形状、类型和数据位置。
 - Name : 张量的名称。
 - Dimensions : 张量的维度信息。
 - Type : 张量数据的类型（如浮点数、整数等）。
 - Offset : 指明张量数据在文件中的位置。
- **对齐填充 (Alignment Padding):** 确保数据块在内存中正确对齐，有助于提高访问效率。
 - 通常是一些填充字节，用于保证后续数据的内存对齐。
- **张量数据 (Tensor Data):** 存储模型的实际权重和参数。
 - Binary Data : 模型的权重和参数的二进制表示。
- **端序标识**⁺ (Endianness): 指示文件中数值数据的字节顺序（大端或小端）。
 - 通常是一个标记，表明文件遵循的端序。

大端模式与小端模式 大端模式是指数据的低位保存在内存的高地址中，而数据的高位保存在内存的低地址中。小端模式是指数据的低位保存在内存的低地址中，而数据的高位保存在内存的高地址中。

- **扩展信息 (Extension Information):** 允许文件格式未来扩展，以包含新的数据类型或结构。
 - 可以是新加入的任何额外信息，为将来的格式升级预留空间。

下面用代码读取一下gguf的格式，看下每个部分的输出

```
import gguf

filename = "/Users/Downloads/tinyllama-1.1b-chat-v1.0.Q4_K_M.gguf"

with open(filename, "rb") as f:
    # Load metadata
    info, tensorinfo = gguf.load_gguf(f)

    # Print metadata
    for key, value in info.items():
        print(f"{key:30} {repr(value)[:100]}")

# Lo. 赞同 13 1 条评论 分享 喜欢 收藏 申请转载 ...
```




理性发言，友善互动

1 条评论

默认 最新



叶遮雨

python pip gguf后 import gguf还是说找不到模块啊🤔

01-30 · 重庆

回复 喜欢

推荐阅读

NCHW与NHWC格式


NCHW与NHWC格式下图很好的描述了各种不同的格式。N代表数量，C代表channel，H代表高度，W代表宽度。NCHW其实代表的是[W H C N]，第一个元素是000，第二个元素是沿着w方向的，即001...

吴建明wujianming

ELF文件解析

ELF(Executable and Linkable Format，可执行与可链接格式)是目前UNIX 和类 UNIX 操作系统的标准二进制格式文件。在 Linux、BSD 变体以及其他操作系统中，ELF 格式用于组织可执行文件、共享...

山东大学-智研院



GGX重要性采样

fuhong



关于GDB你需要知道的

程序喵大人 发表于程序