




机器之心 原创

2025/03/01 21:02

ICLR 2025 | AI不语，只是一味根据人类意图推理3D空间定位

机器之心 | Alxiv

Alxiv专栏是机器之心发布学术、技术内容的栏目。过去数年，机器之心Alxiv专栏接收报道了2000多篇内容，覆盖全球各大高校与企业的顶级实验室，有效促进了学术交流与传播。如果您有优秀的工作想要分享，欢迎投稿或者联系报道。投稿邮箱：liyazhou@jiqizhixin.com；zhaoyunfeng@jiqizhixin.com



图一：我们引入了3D意图定位（右），这一新任务旨在根据人类意图句子（例如：“我想要一个能支撑我的背部、缓解压力的物品”），在3D场景中通过3D边界框检测目标物体。相比之下，现有的3D视觉定位（左）依赖于人类的推理和参考来进行检测。该示意图清晰地区分了观察和推理的执行方式：左侧由人类手动完成，右侧则由AI自动完成。

INTENT3D: 3D OBJECT DETECTION IN RGB-D SCANS BASED ON HUMAN INTENTION

Weitai Kang^{1*}, Mengxue Qu², Jyoti Kini³, Yunchao Wei², Mubarak Shah³, Yan Yan¹¹University of Illinois Chicago, ²Beijing Jiaotong University, ³University of Central Florida

- 项目代码: <https://github.com/WeitaiKang/Intent3D>

介绍

在现实世界中，AI 能够根据自然语言指令执行目标检测，对人机交互至关重要。过去的研究主要集中在视觉指引（Visual Grounding），即根据人类提供的参照性语言，在 2D 图像或 3D 场景中定位目标物体。

然而，人类在日常生活中寻找目标物品往往是起源于某个特定的意图。例如，一个人可能会说：“我想找个东西靠着，以缓解背部压力”，而不是毫无理由的直接描述“找到椅子”或“找到沙发”。

什么是 3D 意图定位（3D-IG）？

目前，3D 视觉指引（3D Visual Grounding, 3D-VG）方法依赖用户提供明确的参照信息，如目标的类别、属性或空间关系。但在许多现实场景下，例如人在忙碌或有视觉障碍时，无法提供这样的参照描述。因此，让 AI 能够自动推理用户的意图并检测目标物体，才是更智能、更自然的交互方式。如图一所示，相较于传统 3D-VG（左图），我们的 3D-IG 任务（右图）能够让 AI 直接基于用户的意图推理目标，而无需明确的物体描述。


为什么选择 3D 而非 2D？

近年来，基于意图的推理任务在 2D 视觉领域有所研究，如意图导向的目标检测（Intention-Oriented Object Detection）、隐式指令理解（Implicit Instruction Understanding）等。然而，这些研究仅限于 2D 视角，无法完整反映现实世界的几何和空间信息。相比之下，3D 数据更加贴近现实世界，不仅包含深度信息，还能提供完整的物体几何、外观特征以及空间上下文。因此，在 3D 场景中进行意图推理，不仅能更准确地模拟真实需求，还能推动智能体（Embodied AI）、自动驾驶、AR/VR 等领域的发展。

数据集 & 基准



标注会限制模型的泛化能力。此外，众包标注往往缺乏可靠性，而专业标注成本高且难以扩展。因此，如图二所示，我们采用 GPT-4 生成意图文本，并经人工质量检查，确保高准确性和多样性。



图二：（上排）数据集构建流程图。构建场景图后，我们根据三个标准选择对象：常见对象、非平凡对象、无歧义对象。我们使用 ChatGPT 根据我们设计的提示生成意图文本。最后，我们手动清理数据。（下排）我们的数据集中针对不同目标数量和文本长度的示例。

其次，为了充分评估我们目前解决这个问题的研究能力，我们使用三种主要的基于语言的 3D 目标检测技术为我们的基准构建了几个基线。这涉及使用以下模型评估我们的数据集：专门为 3D 视觉定位设计的专家模型（BUTD-DETR, EDA）、为通用 3D 理解任务制定的基础模型（3D-VisTA）以及基于大型语言模型 (LLM) 的模型（Chat-3D-v2）。我们使用多种设置评估这些基线，即从头开始训练、微调和零样本。


方法

如何解决 3D 意图定位问题？

如图三所示，我们设计了一种新方法 IntentNet，结合多个关键技术：

- 动宾对齐（Verb-Object Alignment）：先识别意图中的动词，再与相应宾语特征进行对齐，提高意图理解能力。

- 级联自适应学习 (Cascaded Adaptive Learning)：根据不同损失函数的优先级，自适应调整损失函数权重，提升模型性能。



图三：IntentNet：（骨干网络）PointNet++ 用于提取点特征；MLP 编码 3D 目标检测器预测的框；RoBERTa 编码文本输入。

（编码器）基于注意力的块用于多模态融合，通过与文本特征的集成来增强框特征。（解码器）具有最高置信度的前 k 个点特征被选择为提出的查询（query），然后通过基于注意力的块进行更新。几个 MLP 用于线性投影查询，以便进行后续的损失计算。（损失函数）该模型学习使用 L_{bce} 将候选框与目标对象进行匹配；查询（query）被训练以识别动词（ L_{vPos} ），与动词对齐（ L_{vSem} ），并与宾语对齐（ L_{voSem} ）。

实验

由于对意图语言理解和推理进行了显式建模，我们的 IntentNet 明显优于所有以前的方法。与验证集上的第二佳方法相比，我们在 Top1-Acc@0.25 和 Top1-Acc@0.5 中分别实现了 11.22% 和 8.05% 的改进。此外，我们分别将 AP@0.25 和 AP@0.5 提高了 9.12% 和 5.43%。同样，在测试集上，我们在 Top1-Acc@0.25 和 Top1-Acc@0.5 中分别获得了 11.06%、10.84% 的改进；在 AP@0.25 和 AP@0.5 中分别获得了 6.72%、5.6% 的改进。

3D-VisTA [Zhu et al., 2023]	Mask3D [Schult et al., 2022]	42.76	30.37	36.1	19.93
Chat-3D-v2 ⁰ [Huang et al., 2023]	PointGroup [Jiang et al., 2020]	5.86	5.24	0.15	0.13
Chat-3D-v2 [Huang et al., 2023]	PointGroup [Jiang et al., 2020]	36.71	32.78	3.23	2.58
IntentNet (Ours)	GroupFree [Liu et al., 2021b]	58.34	40.83	41.90	25.36

Table 2: 3D intention grounding results on Intent3D's test set. ⁰ indicates the zero-shot results. The best results are in **bold**, and the second best results are underlined.

Method	Detector	Top1-Acc@0.25	Top1-Acc@0.5	AP@0.25	AP@0.5
BUTD-DETR [Jain et al., 2022]	GroupFree [Liu et al., 2021b]	47.86	25.74	31.41	13.46
EDA [Wu et al., 2023]	GroupFree [Liu et al., 2021b]	44.00	19.62	14.56	5.18
3D-VisTA [Zhu et al., 2023]	Mask3D [Schult et al., 2022]	43.88	<u>31.44</u>	<u>37.29</u>	<u>22.00</u>
Chat-3D-v2 ⁰ [Huang et al., 2023]	PointGroup [Jiang et al., 2020]	5.63	4.93	0.14	0.11
Chat-3D-v2 [Huang et al., 2023]	PointGroup [Jiang et al., 2020]	33.46	29.32	2.67	2.1
IntentNet (Ours)	GroupFree [Liu et al., 2021b]	58.92	42.28	44.01	27.60

图四：实验结果

工程

Intent3D

ICLR 2025



推荐文章



ROTK! OpenAI对战中国 Dota2大神再次惨败

机器之心

2



你好, 人工智能分子; 你好, 虚伪弱智时代 | 特写

微胖

2



ACL 2018 | 问答模型真的理解问题吗: 归因分析可...

机器之心

2

登录后评论





暂无评论~



[关于我们](#)

[服务条款](#)

全球人工智能信息服务

友情链接: [Synced Global](#)

[机器之心 Medium 博客](#)

[PaperWeekly](#)

[动脉网](#)

[艾耕科技](#)

