

LLM「想太多」有救了，高效推理让大模型思考过程更精简

新智元 · 2025年04月07日 09:35

华人研究者解决LLM过度思考，提升推理效率。

大模型虽然推理能力增强，却常常「想太多」，回答简单问题也冗长复杂。Rice大学的华人研究者提出高效推理概念，探究了如何帮助LLM告别「过度思考」，提升推理效率。

LLM的推理能力显著增强，然而，这个「超级大脑」也有自己的烦恼。

有时候回答会绕好大一个圈子，推理过程冗长又复杂，虽能得出正确答案，但耗费了不少时间和计算资源。

比如问它「2加3等于多少」，它可能会从数字的概念、加法原理开始，洋洋洒洒说上一大通，这在实际应用中可太影响效率啦。

来自Rice大学的华人研究者提出了「高效推理」的概念，在保证回答准确的同时，更快、更简洁地给出答案。

Stop Overthinking: A Survey on Efficient Reasoning for Large Language Models

Yang Sui, Yu-Neng Chuang, Guanchu Wang, Jiamu Zhang, Tianyi Zhang, Jiayi Yuan, Hongyi Liu, Andrew Wen, Shaochen (Henry) Zhong, Hanjie Chen, Xia Hu
Department of Computer Science
Rice University
yang.sui@rice.edu, xia.hu@rice.edu

Project Website: <https://github.com/Eclipsess/Awesome-Efficient-Reasoning-LLMs>

论文链接: <https://arxiv.org/abs/2503.16419>

项目链接: <https://github.com/Eclipsess/Awesome-Efficient-Reasoning-LLMs>

接下来，深入探讨LLM的高效推理，帮它们告别「过度思考」。

别让模型「想太多」，迈向高效推理

LLM通过思维链（CoT）提示等技术，在复杂推理任务中表现亮眼。

CoT就像是给模型装上了「思考引擎」，让它能一步一步地推导，把推理过程清晰地展现出来。

不过，这份出色的表现，需要消耗大量计算资源。

下一篇

“北漂女孩”回乡创业，利润百万
意比北上广更好做

雷雨下沉市场创业，珠宝香氛年
策略成功。

2025-04-07



TA没有写简介，但内容
发表文章3064篇

最近内容

GPT-4.1深夜登场，中
上下文编程惊人，GPT
2小时前

推理AI“脑补”成瘾，废
学霸揭开内幕
15小时前

刚刚，AI破解50年未解
用OpenAI模型完成首
15小时前

阅读更多内容



企服圈子

- 软件选型经验交流
- 36氪企服点评订阅
- 36氪企服点评服务

企服软件推荐






Figure 1: The pipeline of developing efficient reasoning for LLMs. A reasoning model can be trained on the base model using SFT, RL, or a combination of both. While reasoning models demonstrate strong reasoning capabilities, they often suffer from the “overthinking phenomenon”, generating unnecessarily lengthy reasoning steps. To improve efficiency, various methods can be applied to reduce redundant steps while maintaining accuracy, or to fine-tune non-reasoning models to incorporate efficient reasoning capabilities. This approach enables the model to answer questions with concise and effective reasoning steps. In this paper, we explore the latest progress in efficient reasoning for LLMs, aiming to provide insights that can guide future research and the development of reasoning-driven applications across various domains.

公众号·新智元

本文聚焦于如何在提升或保持模型性能的同时，优化推理过程，这对计算资源有限的实际场景十分重要。

研究者梳理了应对「过度思考」，实现高效推理的技术手段：

- 基于模型的高效推理：即考虑将模型优化为更简洁的推理模型，或直接训练高效推理模型。
- 基于推理输出：旨在推理过程中动态减少推理步骤和长度。
- 基于输入提示：根据输入提示的属性（如难度或长度控制）提高推理效率。

此外，研究者还介绍了用高效数据训练推理模型，探索小模型的推理能力，并讨论了评估方法和基准测试。

认识「过度思考」

LLM产生冗长、不必要的推理过程时，就出现了「过度思考」现象。

在回答「0.9和0.11哪个大」这个简单的问题时，DeepSeek-R1和QwQ-32B这两个模型给出的答案都十分冗长。

它可能会从十进制的原理开始，分析小数点后的每一位数字，还会尝试用各种方法验证，比如转化为分数或在数轴上表示，最后才给出答案。

虽然答案是对的，但推理过程又长又啰嗦，耗费了大量时间和计算资源。




Figure 4: An example of the “overthinking phenomenon”: when asked “Which is larger, 0.9 or 0.11?”, the reasoning model takes an unnecessarily long time (e.g., 19 seconds for QwQ-32B [84])

DeepSeek-R1: 好的, 我得判断0.9和0.11谁更大。它们都是小数, 但小数点后的位数不一样。我先想想每个小数的含义, 0.9就是十分之九, 因为小数点后第一位是十分位。等等, 我换个方法确认下, 把它们转成百分数试试.....为了确保没错, 我在数轴上表示一下吧。还有其他验证方法吗? 用减法好像也行.....或者.....我确定答案是0.9。(616字, 19秒)

QwQ-32B: 要找出0.9和0.11哪个大。它们是小数, 逐位比较看看? 我回忆下小数比较的规则.....0.9 小数点后有1位, 0.11有2位, 写法上是不是要调整下.....不对, 我再检查下, 是不是哪里搞错了。换个思路.....另一种方法是.....最终答案是0.9更大。(602字, 42秒)

从这个例子, 能看出「过度思考」的几个特点: 回答简单问题, 两个模型都写了600多字。推理过程中有很多重复、多余的验证方法。

推理内容越长, 处理所需的时间就越多。模型会反复怀疑自己的推理过程。

在资源有限的环境, 或像自动驾驶、智能交互助手这类需要实时响应的应用场景中, 「过度思考」带来的效率低下问题就会格外突出。

开启高效推理

高效推理方法有以下三类, 基于模型的有效推理、针对结果的优化和借助输入提示的有效推理。




Figure 2: Overview of efficient reasoning methods, which can be summarized as model-oriented (Left: I, II) and reasoning output-oriented (Middle: III, IV), and input prompts-oriented (Right: V, VI) methods. Specifically, (I) Reinforcement Learning with Length Reward Design (Section 3.1); (II) Supervised Fine-Tuning with Variable-Length CoT Data (Section 3.2); (III) Compressing Reasoning Steps into Fewer Latent Representation (Section 4.1); (IV) Dynamic Reasoning Paradigm during Inference (Section 4.2); (V) Prompt-guided Efficient Reasoning (Section 5.1); (VI) Routing Prompts to Optimize Reasoning Efficiency (Section 5.2);

基于模型的有效推理

一种有效的做法是在RL中加入长度奖励, 引导它生成简洁的推理。

以前, 模型训练的时候主要关注答案是否正确、格式是否规范。现在研究人员给它加了一个新的「考核指标」——推理长度。

就像老师不仅要求学生答对题, 还要求答题过程简洁明了。




Figure 5: Illustration of the method for RL fine-tuning with length reward designs. In principle,

奖励函数通常是这样的：

$$R = R_{accuracy} + \alpha * R_{length}$$

其中 α 用来调节长度惩罚在奖励函数中的权重， R_{length} 是根据推理响应长度设置的惩罚项，计算方式如下：

$$R_{length} = -\beta * (length_{of response})$$

模型为了获得更多奖励，就会在保证答案准确的同时，尽量少用token。

Table 1: Comparison of different length reward-based RL methods. $L(\cdot)$ denotes the way of calculating the prediction length. r_0^c/r_0^w denotes reward (correct/wrong) for $L(\cdot)=0$. r_L^c/r_L^w Reward (correct/wrong) for $L(\cdot) = L_{max}(\cdot)$. r_e is the exceed length penalty. y_{GT} represents the ground truth answer of input data x . π_{ref} is the policy of reference model.

Method	RL	Length Constraint Reward	Data	Model
O1-Pruner [57]	PPO	$\mathbb{E}_{x \sim D} [\mathbb{E}_{\pi_{\theta}, \pi_{ref}} [\frac{L(y_{ref})}{L(y_{pred})}] - 1]$	GSM8K GaoKao MATH-500	Marco-o1-7B QwQ-32B-Preview
Demystifying [104]	PPO	$\begin{cases} r_0^c + 0.5 \times (r_L^c - r_0^c)(1 + \cos(\frac{\pi L(y_{pred})}{L_{max}})), & \text{if correct,} \\ r_0^w + 0.5 \times (r_L^w - r_0^w)(1 + \cos(\frac{\pi L(y_{pred})}{L_{max}})), & \text{if wrong} \\ r_e, & \text{if } L(y_{pred}) = L_{max}, \end{cases}$	MATH-500 AIME-2024 TheoremQA MMLU-Pro-1k	LLaMA-3.1-8B Qwen2.5-7B-Math
L1 [1]	GRPO	$\begin{cases} x_{new} = \text{CONCAT}(x, \text{"Think for } N \text{ tokens."}), \\ r(y, y_{GT}, L(y_{GT})) = \mathbb{I}(y_{pred} = y_{GT}) - \alpha \cdot L(y_{GT}) - L(y_{pred}) \end{cases}$	AMC GPQA LAST MMLU MATH-500 AIME-2024 Olympiad-Bench	DeepSeek-R1-Distill-Qwen-1.5B
DAST [74]	SimPO	Trained with constructed length preference data	MATH-500 AIME-2024	DeepSeek-R1-Distill-Qwen-8B DeepSeek-R1-Distill-Qwen-32B
Training [3]	PG	$\mathbb{E}_{x \sim D} [\mathbb{I}\{y_{GT} = y_{pred}\}(1 - \alpha f(L(y_{pred})))]$	GSM8K MATH-500 AIME-2024	DeepSeek-R1-Distill-Qwen-1.5B DeepSeek-R1-Distill-Qwen-7B

利用可变长度的CoT数据进行监督微调，也是提升推理效率的有效方法。

这就好比给模型提供了不同难度和长度的「练习题」，让它学会灵活应对各种情况。

 The key question is: How to collect variable-length CoT reasoning data, especially for short CoT data?




Figure 6: Illustration of methods for utilizing SFT with variable-length CoT reasoning datasets.

训练数据中既有完整详细的推理链，也有简短、高效的推理路径。

通过这些示例，模型就能学会在不降低准确性的前提下，采用更简洁高效的推理模式。

下一篇

“北漂女孩”回乡创业，利润百万
意比北上广更好做

雷雨下沉市场创业，珠宝香氛年
策略成功。

2025-04-07

首页
快讯
资讯
直播
视频
专题
活动

搜索

寻求报道

我要入驻

城市合作

Table 3: Comparison of various approaches that utilize SFT with variable-length CoT reasoning datasets.

Method	Source Data	Reasoning Pruning	SFT	LLMs
Self-Training [62]	GSM8K MATH	Sampling N reasoning then select the shortest one	Standard	Llama-3.2-{1B,3B} Llama-3.1-8B
TokenSkip [95]	GSM8K MATH	Skip tokens according to semantic importance	Standard	LLaMA-3.1-8B-Instruct Qwen2.5-Instruct
C3oT [40]	GSM8K MathQA ECQA StrategyQA	GPT-4 as compressor to make concise reasoning	Standard	Llama-2-chat-{7B,13B}
Distilling2-1 [105]	OASST2	Removing reasoning	Standard	Llama-2-70B-chat
Token-Budget [34]	GSM8K GSM8K-Z MathBench	Persuing an optimal token budget for LLMs to complete the reasoning	Standard	Llama-3.1-8B-Instruct
CoT-Value [59]	GSM8K PRM800k	Merging parameters of non-reasoning and long reasoning LLMs	Progressive	QwQ-32B-Preview DeepSeek-R1-Distill-Llama-8B LLaMA-3.1-8B LLaMA-3.2-1B Qwen32B-Instruct
LearnSkip [53]	Analog of Algebra Multi-digit Addition Directional Reasoning	Stage 1: Manually skipping Stage 2: Prompting LLMs for shorter reasoning	Standard & Progressive	Llama-2-7B Phi-3-mini (3.8B)

下一篇

“北漂女孩”回乡创业，利润百万
意比北上广更好做

雷雨下沉市场创业，珠宝香氛年1
策略成功。

2025-04-07

在微调模型的时候，既可以采用像LoRA这样的标准微调方法，对模型参数进行小范围的调整；也可以采用渐进式微调，让模型慢慢适应新的思考节奏，逐步提高推理效率。

优化推理输出，精简思考过程

从推理输出的角度，研究人员尝试通过创新的方式来压缩推理步骤，让模型的「思考过程」更加精简。

这些方法不改变模型的参数，直接对推理输出的结果进行优化。

潜在推理技术能把推理步骤压缩为更精简的表达形式，图中展示了多种以更高效的格式编码的潜在推理方法：

- Coconut：在训练过程中，逐渐减少推理内容的冗长部分。
- CODI：运用自蒸馏的方式，压缩推理内容。
- CCOT：把CoT推理压缩为潜在表征。
- SoftCoT：借助小型辅助模型，将潜在思维投射到较大的模型中。




Figure 7: Comparison of methods of compressing reasoning steps into fewer latent representations.

这些方法通常会用到嵌入函数，把冗长的推理内容映射到一个更紧凑的空间里，用公式表示就是：

$$E_{compact} = f(E_{verbose})$$

除了利用潜在表示，在推理过程中动态调整推理策略也是提高效率的关键。

动态推理会根据每个问题的具体情况，按需生成推理步骤，图中介绍了两种典型的技术。




Figure 8: Examples of efficient Best-of-N sampling methods. (Left) *Speculative Rejection* [81] uses a reward model to estimate partial generation quality. It then early stops the sampled sequence with lower scores. (Right) *ST-BoN* [91] evaluates the latent embedding of the early generation. The latent embedding of each thinking path will be used to calculate pairwise consistency between other tokens. The sequence with the highest consistency is more likely to arrive at the correct answer.

在奖励引导方面，推测拒绝优化了最佳N解码算法。在生成多个响应的过程中，根据奖励模型的评估，及时丢弃低质量的输出，减少不必要的计算开销。

面对复杂问题时，它会先大量生成可能的推理路径，然后快速排除那些没有希望的路径，只保留高质量的路径继续推理，大大提高了推理效率。

这两种技术的核心思路都是，根据问题的复杂程度灵活调整推理深度，用公式表示为：

$$reasoning_{length} = f(problem_{complexity})$$

借助输入提示，巧妙引导思考

从输入提示的角度入手，也能让模型推理变得更高效。

Table 5: A summary of prompts used with reasoning models to generate concise reasoning outputs. For further details, refer to Section 5.1.

Method	Prompt
TALE-EP [34]	Budget Estimation: (...) Task: Analyze the given question and estimate the minimum number of tokens required to generate a complete and accurate response. Please give the response by strictly following this format: [[budget]], for example, Budget: [[12]]. Token-budget-aware CoT: Please answer the above question. Let's think step by step and use less than <Token-Budget> tokens.
CoD [99]	Think step by step, but only keep a minimum draft for each thinking step, with 5 words at most. Return the answer at the end of the response after a separator ####.
CCoT [69]	Be concise.
Token Complexity [43]	BulletPoints (...) only use bullet points. OnlyNumbers (...) only use numbers or equations. NoSpaces (...) do not use any spaces or line breaks. NoProperGrammar (...) do not use proper grammar. AbbreviateWords (...) abbreviate words as much as possible. WordLimit(k) (...) use at most k words. $k \in \{1, \dots, 100\}$ CharLimit(k) (...) use at most k letters. $k \in \{1, \dots, 500\}$ TokenLimit(k) (...) use at most k tokens. $k \in \{1, \dots, 500\}$ StepLimit(k) (...) use at most k steps. $k \in \{1, \dots, 5\}$ ChineseCoT (...) Respond in Chinese ChineseCoT(k) (...) Use at most k Chinese characters. $k \in \{1, \dots, 500\}$

长度约束提示简单又实用，直接在提示里要求模型控制推理长度，比如「用不超过10个token回答下面的问题」。

下一篇

“北漂女孩”回乡创业，利润百万
意比北上广更好做

雷雨下沉市场创业，珠宝香氛年1
策略成功。

2025-04-07

首页

快讯

资讯

直播

视频

专题

活动

搜索

寻求报道

我要入驻

城市合作

比如在解答数学题时，模型不再详细写出每一步的推导过程，而是用简洁的几个词概括关键思路，这样在保证准确性的同时，大大减少了token的使用。

不同的任务难度不同，对推理的要求也不一样。

因此，根据输入提示的属性进行推理路由也是一种提高效率的策略。

RouteLLM训练了一个查询路由器，它根据问题的复杂性将查询分配给合适的模型。

简单的问题就交给速度快但推理能力较弱的模型处理，复杂的问题则交给能力更强的模型，这样可以充分发挥不同模型的优势，提高整体推理效率。

Self-Ref方法让LLM能根据自身的不确定性分数来决定是否需要路由到更强大的模型。

如果模型对自己的答案不太确定，就会自动寻求更强大模型的帮助，减少不必要的推理步骤。

其他探索

除了上述方向，研究人员还在数据、模型和评估等方面进行了深入探索，以进一步提升LLM的推理效率。

用更少数据，办更多事

很多研究发现，训练数据的质量和结构，对模型的高效推理能力影响很大。

通过精心挑选和组织训练数据，即使数据量少，也能让模型有出色的表现。

- **数据多样性**：让模型接触各种推理模式和问题类型。
- **数据质量**：选择高质量的样本，而不只追求数量多。
- **推理结构**：明确教模型逐步推理，而不是直觉推理。

LIMO打破了传统的观念，不再追求数据的数量，而是专注于质量。

它会从难度、通用性和知识多样性等方面挑选高质量的问题，然后再配上结构合理、验证严格的解决方案。

用这精心挑选的817个样本，LIMO训练出来的模型就能超越那些用了10多万个样本训练的模型，是不是很厉害？

S2R给LLM注入了自我验证和自我纠正的能力，就像给模型请了一个私人教练。

它先在一个精心挑选的数据集上对模型进行微调，让模型初步具备这些能力，然后再通过RL进一步提升。

只用了3100个初始化样本，S2R微调后的模型在推理任务中的表现，比很多用大量长CoT蒸馏数据训练的模型还要好。

小模型的「逆袭之路」

LLM虽然能力很强，但它对计算资源的要求也很高，在一些资源有限的场景里就有点施展不开。

这时候，小语言模型（SLM）就有了用武之地。

不过，要设计出在有限资源下也能有强推理能力，还得给它们上「特殊训练」。

下一篇

“北漂女孩”回乡创业，利润百万
意比北上广更好做

雷雨下沉市场创业，珠宝香氛年销
策略成功。

2025-04-07

知识蒸馏是提升SLM推理能力的重要方法，简单来说，就是把LLM的智慧传递给SLM。

混合蒸馏就像是把不同的「知识精华」混合在一起，有的把长、短CoT推理示例混合，有的把CoT和PoT（Program of Thought）结合，让SLM能吸收更全面的知识。

反事实蒸馏则像是给SLM创造了一些假设情境，通过对原始问题进行特殊处理，生成多视角的CoT，让SLM从不同角度学习知识。

还有反馈驱动的蒸馏技术，它会不断优化蒸馏数据集，像给SLM提供越来越精准的学习资料。

另外，一些方法还把探测和检索机制融入蒸馏过程，或者在蒸馏时让模型根据任务动态调整推理策略，这些都帮助SLM更好地学习LLM的推理能力。

评估推理能力

评估高效推理，需要综合考虑准确性和推理效率：

- **准确性**：看最终给出的答案是否正确。
- **效率**：token使用数量、推理花费的时间、消耗的计算资源。

实际评估时，通常会先把效率指标标准化处理，再和准确性指标结合起来，形成一个综合指标：

$$Combined_Score = Accuracy * (1 - normalized_token_count)$$

既奖励正确性，又鼓励推理的简洁性。

Sys2Bench涵盖了算术、逻辑、常识、算法和规划等多个领域的任务，用11个不同的数据集对LLM进行全方位的测试。

通过这个测试，发现仅靠增加推理时的计算资源，并不能让模型在所有任务中都表现出色，提升LLM的推理能力需要多种方法结合。

还有一些研究专门考察不同的推理策略对模型性能的影响，以及测试时扩展（TTS）策略和模型性能之间的关系。

对LLM的过度思考问题，也有专门的评估方法。

研究人员开发了一个评估框架，可以深入分析模型的推理过程，找出像分析瘫痪、异常行为和过早放弃等模式。

他们提出了「过度思考分数」，就像是一个健康指标，分数越高，说明模型过度思考的问题越严重，任务性能就越差。

通过选择过度思考分数低的解决方案，可以让模型性能提高30%，同时降低43%的计算开销。

参考资料

<https://www.alphaxiv.org/overview/2503.16419>

本文来自微信公众号“[新智元](#)”，作者：英智，36氪经授权发布。


该文观点仅代表作者本人，36氪平台仅提供信息存储空间服务。

下一篇

“北漂女孩”回乡创业，利润百万
意比北上广更好做

雷雨下沉市场创业，珠宝香氛年1
策略成功。

2025-04-07



广告

下一篇

“北漂女孩”回乡创业，利润百万
意比北上广更好做

雷雨下沉市场创业，珠宝香氛年1
策略成功。

2025-04-07

36

好文章，需要你的鼓励

参与评论

评论千万条，友善第一条


登录后参与评论

0/1000 提交评论

你可能也喜欢这些文章



AI上演权力游戏，MCP与A2A筑起“小院高墙”？



AI成都 | 立足先发优势，「恒图科技」正探索数字创意产业发展...



离谱又上头！AI应用都能这样“玩”了？ | 2025 AI Partner...



GPT-4.1深夜登场，中科大校友领队，百万上下文编程惊人，...



GPT-4.1深夜偷袭，OpenAI掏出史上最小、最快、最便宜三大...



AI网页版扎堆上线，华为、理想、OPPO们打的什么算盘？



刚刚，OpenAI 发布 GPT-4.1，吊打 GPT-4.5，14 万/月的博...



微软的AI游戏翻车，直接生成游戏或是条不归路



推理AI“脑补”成瘾，废话拉满，马里兰华人学霸揭开内幕

关于36氪

- 城市合作
- 商务合作
- 寻求报道
- 关于我们
- 我要入驻
- 联系我们
- 投资者关系
- 加入我们

热门推荐

- 热门资讯
- 热门产品
- 文章标签
- 快讯标签

合作伙伴

 阿里云

 火山引擎

 高德地图

 星球日报

 鲸准

 氪空间

 企服点

 人人都说

 领氪

下一篇

 个推

“北漂女孩”回乡创业，利润百万，意比北上广更好做

雷雨下沉市场创业，珠宝香氛年销1000万，策略成功。

2025-04-07

网络谣言信息举报入口



本站由 阿里云 提供计算与安全服务 违法和不良信息举报电话：010-89650707 举报邮箱：jubao@36kr.com 网上有害信息举报

© 2011~2025 北京多氪信息科技有限公司 | 京ICP备12031756号-6 | 京ICP证150143号 | 京公网安备11010502036099号

活动

搜索

寻求报道

我要入驻

城市合作

特邀作者

9

0

举报