



公众号 · 旺知识

## MiniCPM-V技术报告详细翻译解读: 端侧GPT-4V级别多模态大语言模型



旺知识  
腾讯 应用研究

3 人赞同了该文章

最近多模态大语言模型(MLLM)的激增从根本上重塑了AI研究和产业的格局,为通往下一个AI里程碑的道路指明了有希望的方向。然而,要使MLLM在现实世界的应用中变得实用,仍然存在重大挑战。最明显的挑战来自于运行具有大量参数和广泛计算需求的MLLM的巨大成本。结果,大多数MLLM只能部署在高性能的云服务器上,这大大限制了它们的应用范围,如移动设备、离线、能耗敏感和注重隐私/保护的场景。在这项工作中,我们介绍了MiniCPM-V<sup>+</sup>,一系列可在端侧设备上部署的高效MLLM。通过整合最新的MLLM技术在架构、预训练和对齐方面,最新的MiniCPM-Llama3-V 2.5<sup>+</sup>具有几个显著特点:(1)强大的性能,在OpenCompass上超过了GPT-4V-1106、Gemini Pro和Claude 3,OpenCompass是一个涵盖11个流行基准的全面评估,(2)强大的OCR能力<sup>+</sup>,支持1.8M像素的高分辨率图像感知,在任何纵横比下,(3)可信行为,低幻觉率,(4)支持30多种语言的多语言,(5)在手机上高效部署。更重要的是,MiniCPM-V可以被视为一个有希望的趋势的代表(图1):实现可用(例如,GPT-4V)级别性能模型大小正在迅速减小,同时端侧计算能力也在快速增长。这共同表明,部署在端设备上的GPT-4V级别的MLLM很快就会出现,在不久的将来开启更广泛的应用场景和利益。

我们翻译解读最新论文: 端侧GPT-4V级别多模态大语言模型, 文末有论文链接。

登录即可查看 超5亿 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。

立即登录/注册



公众号 · 旺知识

作者：张长旺，图源：旺知识




Figure 1: Moore's Law for MLLM? Trends of MLLM development in terms of time (x-axis), model size (y-axis), and performance (color). The red line shows the decreasing model sizes for achieving GPT-4V level performance, while the blue line represents the growing end-side computation capacity. This jointly shows that GPT-4V level MLLMs deployed on end devices are becoming increasingly possible, unlocking a wider spectrum of real-world AI applications in the near future.

图1:MLLM发展的摩尔定律?MLLM发展的趋势,以时间(x轴)、模型大小(y轴)和性能(颜色)为度量。红线显示了实现GPT-4V级别性能模型大小在快速减小,而蓝线代表了端侧计算能力的增长。这共同表明,部署在端设备上的GPT-4V级别的MLLM变得越来越可行,在不久的将来将开启更广泛的现实世界AI应用领域。

## 1 - 引言

多模态大型语言模型(MLLM)[83,2,68,62,102,23,7,41,52,76,11]的快速发展带来了在理解、推理和交互方面的多模态能力的令人印象深刻的激增。这不仅从根本上重塑了AI研究和产业格局,而且还为通往下一个AI里程碑的道路指明了有希望的方向。然而,当前的MLLM在现实世界的应用中还远远不够实用。最突出的挑战之一是,当前的MLLM通常涉及大量的参数,并带来沉重的计算负担。结果,大多数MLLM只能部署在高性能的云服务器上,导致显著的能源消耗和

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



鉴于这些限制,人们越来越有兴趣探索更高效的轻量级MLLM[1,68,83,11],它们可以在端侧设备上运行。端侧场景涵盖了更广泛的设备范围,包括手机、个人电脑、车辆和机器人等,它们在用户的日常生活中无处不在,并且计算能力正在快速发展。由于其更广泛的使用范围、更好的计算效率、更强大的离线行为和更好的隐私/安全保护,端侧MLLM为更实用的应用提供了有希望的解决方案。

然而,开发有能力的端侧MLLM具有挑战性,因为参数和推理计算预算受到显著限制。结果,需要更精心的架构设计和训练方案,以充分发挥端侧MLLM的潜力。在这项工作中,我们介绍了MiniCPM-V,一系列可在端侧设备上部署的高效MLLM。MiniCPM-V的理念是在性能和效率之间实现良好的平衡,这在现实世界的应用中是一个更重要的目标。到目前为止,在2024年,我们已经推出了三个模型:(1)在2月,我们推出了MiniCPM-V 1.0 2B,这是为手机设计的第一批MLLM之一。(2)在4月,我们推出了MiniCPM-V 2.0 2B,在性能上超过了Qwen-VL 9B[7]、CogVLM 17B[102]和Yi-VL 34B[108]等大型MLLM。这个版本还引入了对高分辨率图像输入的支持,并展示了有希望的OCR能力。(3)最近在5月,我们发布了MiniCPM-Llama3-V 2.5 8B,在OpenCompass评估中超过了强大的GPT-4V-1106、Gemini Pro和Claude 3。这个模型值得注意的特点包括强大的OCR能力、高分辨率图像感知、可信行为、多语言支持和高效的端侧部署优化。

更重要的是,MiniCPM-V可以被视为一个有希望的趋势的代表。图1总结了最近的MLLM发展[1,68,57]在性能、参数和发布时间方面的情况。我们观察到一个有趣的趋势,类似于摩尔定律[103]所指示的红线:达到GPT-4V级别性能的模型大小正在迅速减小。这种现象或许可以被称为MLLM的摩尔定律。与此同时,端侧设备(如手机和个人电脑)的计算能力正在稳步增长(由蓝线定性描述)。这两种趋势的汇聚表明,部署在端侧设备上的可用的(例如,GPT-4V级别)MLLM很快就要实现了,这将在不久的将来开启更广泛的可能性,并使更多的应用场景受益。

从人类技术发展的历史上看,这一趋势也可以被视为人类对尖端技术小型化的追求,这在其他科学和技术领域也一再被见证。例如,在航天领域,最新的SpaceX Raptor 2火箭引擎的质量为1.6吨,可以产生高达2256千牛的推力,而20年前,RD-0750火箭引擎的质量超过4吨,只能产生1413千牛的推力[104]。

MiniCPM-V系列技术。在本文中,我们将以最新的MiniCPM-Llama3-V 2.5为例,系统地介绍MiniCPM-V系列的显著特点和背后的关键技术:

- 领先的性能。**MiniCPM-Llama3-V 2.5在OpenCompass集合上的性能优于GPT-4V1106、Gemini Pro和Claude 3,这是一个涵盖11个流行基准的全面评估。这得益于其在架构、数据和训练方案方面的精心设计,我们将在以下部分详细介绍。

- 强大的OCR能力。**MiniCPM-Llama3-V 2.5在OCRBench上胜过GPT-4V、Gemini Pro和QwenVL-Max。它还支持高实用性功能,如表格转Markdown转换和完整的OCR内容转录。这在很大程度上归功于1.8M像素高分辨率(例如1344×1344)图像感知技术,适用于任何纵横比[107]。

- 可信行为。**基于RLAIF-V+[112]和RLHF-V[111]技术,通过AI/人类反馈使MLLM行为与期望对齐,MiniCPM-Llama3-V 2.5展现出更可信的行为,在Object HalBench上比GPT-4V-1106实现了更低的幻觉率。

- 多语言支持。**受到VisCPM+[41]的发现的启发,多语言LLM的整合大大减轻了低资源语言对多模态训练数据的严重依赖。在这一基础上,高质量的多语言多模态指令调整帮助MiniCPM-Llama3-V 2.5将其多模态能力泛化到30多种语言。


- 高效的端侧部署。**我们系统地整合了一系列端侧优化技术,包括量化、内存优化、编译优化和NPU加速,实现了在端侧设备的高效部署。

我们希望MiniCPM-V系列能够作为揭示端侧MLLM潜力的典范,并帮助吸引更多的关注,以推动这一研究方向的发展。遵循MLLM的摩尔定律,我们相信将会出现越来越强大的端侧MLLM,规模更小,很快就能在设备上带来高效、安全、可信的AI服务。

这项工作的贡献总结如下:(1)我们介绍并开源了MiniCPMV,这是一系列在性能和效率之间实现良好平衡的高效端侧MLLM。(2)我们研究了推动MLLM实现大规模性能-效率平衡的关键技术,

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



## 2 - 相关工作

多模态大型语言模型。LLM的发展显著推进了MLLM的进展。Flamingo[4]首次提出将预训练的视觉编码器与Chinchilla 70B[40] LLM连接起来,展示了MLLM在一系列视觉语言任务中的零样本和少样本能力。在ChatGPT出现之后,包括BLIP-2[54]、Kosmos-1[43]、MiniGPT-4[121]、LLaVA[62]和VPGTrans[117]在内的许多开源模型被提出。其中大多数是建立在现有的预训练LLM如Llama[100]和Vicuna[120]的基础上,而Kosmos-1则试图从头开始训练LLM。后来,研究人员继续扩展MLLM的功能范围,提高视觉感知能力。Kosmos-2[80]、CogVLM[102]、Shikra[20]和NEXt-Chat[116]进一步将本地化能力整合到MLLM中,无论是通过pix2seq范式还是与检测/分割模型连接。Qwen-VL-Chat[7]、Yi-VL[108]、DeepSeek-VL[68]、InternVL[23]和Intern-XComposer[31]更注重通过高分辨率输入、更多的训练数据和更好的数据比例等不同技术来提高模型的能力。




Figure 2: Qualitative results of MiniCPM-Llama3-V 2.5 in reading text in images, converting to markdown, performing complex reasoning, and multilingual interaction, etc. See [here](#) for screen recordings of MiniCPM-Llama3-V 2.5 running on mobile phones.

图2:MiniCPM-Llama3-V 2.5在图像中阅读文本、将表格转换为markdown、执行复杂推理和多语言交互等方面的定性结果。请参阅MiniCPM-Llama3-V 2.5在手机上运行的屏幕录像。

登录即可查看 [超5亿](#) 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。






Figure 3: Model architecture. (a) **Overall structure** presents the architecture of the model including the visual encoder, shared compression layer, and LLM. (b) **Adaptive visual encoding** deals with high-resolution inputs in various aspect ratios.

图3:模型架构。(a)整体结构展示了包括视觉编码器、共享压缩层和LLM在内的模型架构。(b)自适应视觉编码处理各种纵横比的高分辨率输入。

端侧多模态大型语言模型。MLLM的大量参数在训练和部署中带来了极高的计算成本,极大地限制了其广泛的应用。最近,有一种趋势是构建参数更少的小型LLM。代表性的模型包括Phi[45]、Gemma[8]、MobileLLM[66]、MiniCPM[42]等。这些模型的适中大小使它们适用于端侧设备,如个人电脑甚至手机。通过优化的训练策略,像MiniCPM 2B这样的端侧LLM可以实现与像Llama2-7B[101]这样的7B强模型相当的性能。在MLLM中也观察到了类似的趋势。例如,Mini-Gemini[57]和PaliGemma[11]是基于Gemma 2B[8]构建的,而MobileVLM V2是基于MobileLlama[25]构建的。然而,端侧MLLM的较少参数特性为构建一个有能力的模型带来了显著的挑战。MiniCPM-V系列旨在通过在架构、训练、推理和部署中进行精心设计,解决关键瓶颈问题,推动端侧MLLM的潜力。

### 3 - 模型架构

在这一部分中,我们介绍了MiniCPM-V的模型架构,概述了整体结构和自适应高分辨率视觉编码方法。MiniCPM-V系列的设计哲学是在性能和效率之间实现良好的平衡,这是一个更实际的目标,适用于更广泛的现实世界应用场景,这在架构设计、训练、推理和部署中得到了实现。

#### 3.1 - 整体结构

该模型由三个关键模块组成:视觉编码器、压缩层和LLM。输入图像首先由视觉编码器编码,采用自适应视觉编码方法。具体来说,我们使用SigLIP SoViT-400m/14[115]作为视觉编码器。然后,视觉标记通过压缩层进行压缩,压缩层采用具有一层交叉注意力的感知器重采样器结构。最后,压缩后的视觉标记与文本输入一起输入LLM进行条件文本生成。


#### 3.2 - 自适应视觉编码

最近,人们越来越认同视觉编码在MLLM性能[76,68]中的基本作用,尤其是对于OCR等细粒度能力。为了有效性,一个好的视觉编码策略应该同时尊重输入的原始纵横比并保留足够的视觉细节(高分辨率)。为了效率,图像编码产生的视觉标记数量应该是适中的,以便在端侧设备上是可以承受的。为此,我们采用了LLaVa-UHD[107]提出的一种自适应视觉编码方法。

**图像分割。**为了处理具有不同纵横比的高分辨率图像,我们将图像分割成切片,每个切片更匹配ViT的预训练设置的分辨率和纵横比。具体来说,我们首先根据输入图像的大小计算理片数。给定一个分辨率为( $W_I, H_I$ )的图像,和一个在分辨率为( $W_v, H_v$ )的图像上预训练的ViT,计算理想切片数 $N = \lceil W_I \times H_I / (W_v \times H_v) \rceil$ 。然后,我们从集合 $CN = \{(m, n) | m \times n = N, m \in \in N\}$ 中选择行数 $n$ 和列数 $m$ 的组合。一个好的分割( $m, n$ )应该产生与ViT的预训练设置很好配的切片。为了实现这一点,我们使用一个评分函数来评估每种可能的分割: $S(m, n) = -\sum(\log(W_I/m) + \log(H_I/n) - \log(W_v/H_v))$ 。

登录即可查看 [超5亿](#) 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



我们从所有可能的候选中选择得分最高的分割:  $m^*, n^* = \arg \max_{(m,n) \in \mathcal{C}} S(m, n)$

$$m^*, n^* = \arg \max_{(m,n) \in \mathcal{C}} S(m, n), \quad (2)$$

其中 $\mathcal{C}$ 是可能的 $(m, n)$ 组合的集合,其乘积为 $N$ 。然而,当 $N$ 是质数时,可行的解决方案可能限于 $(N, 1)$ 和 $(1, N)$ 。因此,我们额外引入了 $CN-1$ 和 $CN+1$ ,并将 $\mathcal{C}$ 设置为 $CN-1 \cup CN \cup CN+1$ 。在实践中,我们设置 $N < 10$ ,在编码期间最多支持180万像素(例如 $1344 \times 1344$ 分辨率)。尽管我们可以为更高的分辨率包含更多的图像切片,但我们故意将分辨率上界设置得较低,因为这已经很好地覆盖了大多数现实世界的应用场景,并且考虑到性能和开销,进一步提高编码分辨率的好处是边缘的。

**切片编码。**尽管图像分割可以确保切片与ViT的预训练设置很好地匹配,但每个切片的大小并不精确地等于 $(W_v, H_v)$ 。为了将切片输入到ViT,我们首先通过按比例调整每个切片来调整它,以便结果的面积大小与ViT预训练的面积大小 $W_v \times H_v$ 匹配。这种调整有助于防止编码补丁的数量与ViT的预训练设置之间存在显著差距。随后,我们插值ViT的位置嵌入以适应切片的比率。这涉及将ViT的1D嵌入 $P1 \in \mathbb{R}^{Q \times l}$ 重新塑造为其2D格式 $P2 \in \mathbb{R}^{q \times q \times l}$ ,其中位置嵌入的数量 $Q = q \times q$ 。然后,我们通过2D插值将 $P2$ 插值以适应每个切片的大小。我们还包括原始图像作为额外的切片,以提供关于整个图像的整体信息。

**标记压缩。**经过视觉编码后,每个切片被编码成1024个标记,10个切片总共可以产生超过10k个标记。为了管理这种高标记数量,我们采用了一个压缩模块,包括一层交叉注意力和适度数量的查询,2D位置信息已知[7]。在实践中,每个切片的视觉标记通过这一层被压缩成64个查询用于MiniCPM V1-2,96个标记用于MiniCPM-Llama3-V 2.5。与其他具有竞争力性能的MLLM相比,MiniCPM-V系列中显著较少的视觉标记数量使其在GPU内存消耗、推理速度、首标记延迟和功耗方面具有更高的效率,使其更适合更广泛的应用范围和社区。

**空间模式。**为了指示每个切片相对于整个图像的位置,受到[9]的启发,我们额外引入了一个空间模式。我们首先用两个特殊标记 $\langle \text{slice} \rangle$ 和 $\langle \backslash \text{slice} \rangle$ 包装每个切片的标记,然后使用特殊标记 $\backslash n$ 来分隔来自不同行的切片。

## 4 - 训练

模型训练包括三个阶段:预训练阶段、监督微调阶段和RLAIF-V阶段。我们将在以下部分介绍训练方案。


### 4.1 - 预训练

在这个阶段,我们使用大规模的图像-文本对进行MLLM预训练。这个阶段的主要目标是将视觉模块(即视觉编码器和压缩层)与LLM的输入空间对齐,并学习基础的多模态知识。预训练阶段进一步分为三个阶段。

**阶段1。**阶段1的作用是预热压缩层,主要连接视觉编码器和LLM。(1)可训练模块。在阶段1,我们随机初始化压缩层,并训练这个模块,同时保持其他参数冻结。视觉编码器的分辨率设置为 $224 \times 224$ ,与视觉编码器的预训练设置相同。(2)数据。为了预热压缩层,我们从表1中的图像字幕数据中随机选择200M数据。进行数据清洗,以去除相关性差和格式不良的文本数据的图像-文本对,确保数据质量。

登录即可查看 [超5亿](#) 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



| Category         |         | Sources                                                                                     | Size |
|------------------|---------|---------------------------------------------------------------------------------------------|------|
| Image Captioning | English | COCO [59], VG [51], CC3M [89], CC12M [17], LAION-COCO [86], COYO [15], LAION-2B [86]        | 410M |
|                  | Chinese | AIC [105], LAION-2B-Chinese [86], WuKong [35], Zero-Chinese [106], etc.                     | 110M |
| OCR+Knowledge    | English | WIT [92], IDL [13], SynthText [37], SynthDoG-en [50], SynthDoG-zh [50], ArxivCap [55], etc. | 39M  |
|                  | Chinese | WIT [92], LAION-2B-OCR [106], etc.                                                          | 11M  |

表1:预训练数据。预训练数据包括英文和中文的图像字幕和OCR数据。LAION-2B-OCR是通过将OCR工具应用于LAION-2B图像生成的。

**阶段2。**在压缩层的预训练之后,阶段2的作用是扩展预训练视觉编码器的输入分辨率。(1)可训练模块。在阶段2,我们将图像分辨率从224×224扩展到448×448。整个视觉编码器都被训练,而其他参数保持冻结。(2)数据。为了扩展预训练分辨率,我们另外从表1中的图像字幕数据中选择200M数据。

**阶段3。**在扩展视觉编码器的主要输入分辨率之后,我们最后使用自适应视觉编码策略训练视觉模块,这可以进一步适应具有任何纵横比的高分辨率输入。(1)可训练模块。在阶段3训练期间,压缩层和视觉编码器都被训练以适应语言模型的嵌入空间。LLM被保持冻结,以避免相对低质量的预训练数据的干扰。(2)数据。与之前阶段只使用图像字幕数据不同,在高分辨率预训练阶段,我们另外引入OCR数据来增强视觉编码器的OCR能力。

**字幕重写。**来自Web [86,15]的图像-文本对可能存在字幕数据质量问题,包括不流畅的内容、语法错误和重复单词。这种低质量的数据可能导致不稳定的训练动态。为了解决这个问题,我们引入了一个辅助模型来重写低质量的字幕。重写模型以原始字幕为输入,并被要求将其转换为问答对。从这个过程中得到的答案被用作更新后的字幕。在实践中,我们利用GPT-4 [14]来注释少量种子样本,然后使用这些样本来微调LLM进行重写任务。

**数据打包。**来自不同数据源的样本通常具有不同的长度。跨批次的样本长度高度变化将导致内存使用效率低下和内存不足(OOM)错误的风险。为了解决这个问题,我们将多个样本打包成一个固定长度的序列。通过截断序列中的最后一个样本,我们确保了序列长度的一致性,有助于更一致的内存消耗和计算效率。同时,我们修改了位置ID和注意力掩码,以避免不同样本之间的干扰。在我们的实验中,数据打包策略可以使预训练阶段的速度提高2到3倍。

Table 2: SFT data for MiniCPM-V series. Part-1&2 data are concatenated sequentially in the SFT phase. Part-1 focuses on bolstering basic recognition capabilities, while part-2 aims to enhance advanced capabilities in generating detailed responses and following human instructions.


| Category | Sources       | Size                                                                                                                                                                                                                                           |
|----------|---------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Part-1   | Short Caption | Flickr-30K [81], COCO [59]                                                                                                                                                                                                                     |
|          | VQA           | FM-IQA [34], VGQA [51], IconQA [69], GQA [44], VQA-v2 [6], CLEVR [46], VizWiz [38], Visual7W [122], COCO-QA [84]                                                                                                                               |
|          | Knowledge     | OKVQA [72], A-OKVQA [87], KVQA [88], ScienceQA [70]                                                                                                                                                                                            |
|          | Grounding     | RefCOCO [109]                                                                                                                                                                                                                                  |
|          | Reasoning     | COMVINT [32], VCR [114], NLVR [94], LRV [60]                                                                                                                                                                                                   |
|          | Math          | GeoQA [19], SMART-101 [24]                                                                                                                                                                                                                     |
|          | OCR           | DocVQA [74], TextVQA [91], OCR-VQA [77], ST-VQA [12], VisualMRC [96], DVQA [47], FigureQA [48], ChartQA [73], DeepForm [95], TabFact [22], InfographicsVQA [75], Kleister Charity [93], WikiTableQuestions [79], Real-CQA [3], AI2D [49], etc. |
|          | Chat          | FSVQA [90], Visual-Dialog [28]                                                                                                                                                                                                                 |
| Part-2   | Part-1        | sample from Part-1 data                                                                                                                                                                                                                        |
|          | OCR           | DocVQA, TextVQA, OCR-VQA, VisualMRC, ChartQA, AI2D, ArxivQA [56], LLaVAR [118], TextOCR-GPT4V [16], etc.                                                                                                                                       |
|          | Instruct      | SVIT [119], LLaVA-Instruct-150K [62], UniMM-Chat [110], ShareGPT4V [21], LVIS [36], ALLaVA [18]                                                                                                                                                |
|          | Text-Only     | Ultra-Chat [30], Alpaca [97], ShareGPT [120], BELLE [10], OpenOrca [58], OpenHermes [98], In-House-MiniCPM-SFT                                                                                                                                 |

表2:MiniCPM-V系列的SFT数据。Part-1和Part-2数据在SFT阶段顺序连接。Part-1专注于基本识别能力,而Part-2旨在提高生成详细响应和遵循人类指令的高级能力。

**多语言泛化。**跨多种语言的多模态能力对于服务更广泛社区的用户至关重要。传统的解决方案涉及广泛的多模态数据收集和清洗,以及针对目标语言的训练。幸运的是,VisCPM [41]的最

登录即可查看 超5亿 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



模态数据进行预训练,然后进行轻量级但高质量的多语言监督微调,以与目标语言对齐。尽管这种方法很简单,但我们发现MiniCPMLlama3-V 2.5在30多种语言上的表现与明显更大的MLLM相当。

## 4.2 - 监督微调

在从预训练中学习基础能力后,我们在高质量的视觉问题回答数据集上执行监督微调(SFT),以从人类注释中进一步学习知识和交互能力。

**可训练模块。**与主要使用来自Web的爬取数据的预训练阶段不同,SFT阶段主要使用由人类标注者或像GPT-4这样的强模型注释的高质量数据集。因此,我们解锁了所有模型参数,以更好地利用数据,在SFT阶段学习丰富的知识。

**数据。**最近的工作[42,83]表明,训练结束时的数据在塑造模型的能力和响应风格方面起着更重要的作用。我们将SFT数据分为两部分。Part-1专注于增强模型的基本识别能力,而Part-2旨在提高它们在生成详细响应和遵循人类指令方面的高级能力。具体来说,Part-1数据包括相对简短的响应长度的传统QA/字幕数据集,这有助于增强模型的基本识别能力。相比之下,Part-2包括在文本或多模态上下文中具有复杂交互的长响应的数据集。在SFT期间,这两部分数据被连接并顺序输入到模型中。对于MiniCPM-Llama3-V 2.5,我们整合了最近Cauldron数据集<sup>†</sup>[52]的200万数据进行多模态知识增强,以及36种语言的9万多语言数据以增强多语言对话能力。

## 4.3 - RLAI-F-V

MLLM通常容易出现幻觉问题,生成与输入图像事实不符的响应[111]。这个问题极大地限制了MLLM的广泛应用,尤其是在高风险场景中,如自动驾驶和为视力受损群体提供帮助。为了解决幻觉问题,我们采用了最近的RLAIF-V [112]方法(图4),其中关键是从开源模型获得可扩展的高质量反馈,以进行直接偏好优化(DPO)[82]。




Figure 4: RLAI-F-V framework for hallucination reduction. (1) **Response generation** produces multiple responses for an instruction using the policy model. (2) **Feedback collection** evaluates the correctness of each response in a divide-and-conquer fashion. (3) **DPO** optimizes the model on the preference dataset.


**响应生成。**RLAIF-V的第一步是使用策略模型为给定指令生成多个响应。具体来说,给定一个等待对齐的模型 $M$ ,我们使用高温度的采样解码从 $M$ 中采样10个响应 $Y = \{y_1, y_2, \dots, y_n\}$ 。使用策略模型 $M$ 进行响应生成有几个好处:(1)反馈收集和学习可以更好地关注可信度,因为避免了来自多个MLLM的不同文本风格。(2)反馈学习更加高效,因为偏好是直接策略模型的分布上收集的。

**反馈收集。**从开源MLLM收集高质量反馈可能是一项挑战,因为它们通常比专有模型具有较弱的的能力。为了解决这个问题,RLAIF-V使用分而治之的策略进行响应评分。具体来说,每个响应 $y_i$ 被Llama-3 8B划分为原子声明 $C_i = \{c_1, c_2, \dots, c_m\}$ ,其中原子声明的正确性更容易评估后,我们通过将每个声明转换为是非问题,并使用开源MLLM对每个声明进行评分来验证声明。在实践中,我们采用OmniLLM 12B对MiniCPM-V 2.0进行评分,采用LLaVA-NeXT-Yi 34B对MiniCPM-Llama3-V 2.5进行评分。响应 $y_i$ 的最终得分 $s_i$ 由 $-n_{rej}$ 给出,其中 $n_{rej}$ 是无效原子声明的数量。

**直接偏好优化。**在收集到高质量AI反馈后,我们通过DPO方法进行偏好学习。DPO算法需要偏好对上进行训练,其中一个样本 $y_w$ 比另一个样本 $y_l$ 更受偏好。为了组成偏好数据集,我们从每

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。






Figure 5: An overview of end-side deployment. Current end-side chips for computation acceleration include CPU, GPU and NPU. We list their generality, (estimated) ideal and current performance, and related deployment frameworks.

图5:端侧部署概述。当前用于计算加速的端侧芯片包括CPU、GPU和NPU。我们列出了它们的通用性、(估计的)理想和当前性能,以及相关的部署框架。

## 5 - 端侧部署

在这一部分中,我们研究了MiniCPM-V在端侧设备的部署。我们首先介绍挑战,然后提出了端侧部署的基本和高级实践。最后,我们分析并讨论了不同设备上的评估结果。

### 5.1 - 挑战

端侧设备,如智能手机和计算机,通常由于散热、尺寸限制和功耗等因素而面临资源限制。我们通过将端侧设备与高性能服务器进行比较,确定了MLLM端侧部署的几个关键挑战:

内存限制。高性能服务器通常拥有广泛的内存容量,通常超过100GB甚至1TB。相比之下,移动电话上的可用内存通常在12GB到16GB之间,这可能不足以部署MLLM。

CPU/GPU速度限制。智能手机中的CPU处理速度明显较慢。例如,Snapdragon 8 Gen3具有8个CPU核心2,而像Intel Xeon Platinum 8580这样的高性能服务器具有60个CPU核心3。同样,移动电话GPU也不像服务器GPU那样强大。例如,高通Adreno 750仅有6 TFLOPS,而NVIDIA 4090可达到83 TFLOPS。

### 5.2 - 基本实践

为了在端侧设备上部署MLLM,我们首先采用量化来降低内存成本,并经验性地研究了不同框架上的部署结果。

**量化。**量化是一种广泛使用的减少内存消耗的技术。模型量化的主要思想是使用统一的缩放因子将多个权重压缩到较窄的范围内,然后进行离散化。这个过程在数学上表示为: $w'_i = \text{round}(w_i / s)$ ,  $\forall 1 \leq i \leq n$ ,


$$w'_i = \text{round}\left(\frac{w_i}{s}\right), \forall 1 \leq i \leq n, \quad (3)$$

其中 $w'$ 表示量化参数, $s$ 表示计算出的缩放因子。 $\text{round}$ 函数将量化值离散化。

对于MiniCPM-Llama3-V 2.5,fp16版本的模型通常需要16到17GB的内存。我们选择GGML4框架中的Q4\_K\_M模式4位量化策略。这将内存需求降低到大约5GB,这对移动电话使用是友好的。

登录即可查看 [超5亿](#) 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。






Figure 6: Ablation study on the Xiaomi 14 Pro (Snapdragon 8 Gen 3). We show the influence of different techniques on the (a) encoding latency and (b) decoding throughput. **No opt.**: non-optimized, **mem. opt.**: memory usage optimization, **comp. opt.**: compilation optimization, **config. opt.**: configuration optimization, **NPU**: NPU acceleration. Note that the encoding latency includes both model loading time and encoding time, which differs from Fig. 5's encoding time only.

图6:在小米14 Pro(Snapdragon 8 Gen 3)上进行的消融研究。我们展示了不同技术对(a)编码延迟和(b)解码吞吐量的影响。无优化:未优化,内存优化:内存使用优化,编译优化:编译优化,配置优化:配置优化,NPU:NPU加速。请注意,编码延迟包括模型加载时间和编码时间,这与图5的仅编码时间不同。

**部署框架。**已经提出了几个用于端侧部署的框架。如图5所示,我们对包括CPU、GPU和NPU在内的不同芯片类型进行了不同的框架进行了彻底的研究。

考虑到CPU在设备中的普遍使用,我们优先选择这种芯片类型,并选择llama.cpp [67]框架。在小米14 Pro(Snapdragon 8 Gen 3)上结合量化和llama.cpp,模型实现了64.2秒的文本编码延迟和1.3个token/秒的文本解码速度(如图6所示),这对于用户来说仍然远远不够。

### 5.3 - 高级实践

为了增强用户体验,我们研究了一系列高级技术,包括内存使用优化、编译优化、配置优化和NPU加速。

**内存使用优化。**实验结果表明,在没有特定优化的情况下,由于移动电话上有限的内存资源,图像处理可能是推理速度的瓶颈。为了解决这个问题,我们探索了内存使用优化策略。我们不是同时将ViT和LLM加载到内存中,而是采用顺序加载方法。具体来说,我们首先加载ViT进行视觉编码,然后加载LLM进行视觉和文本标记编码。通过释放LLM占用的大量内存,我们可以防止ViT编码期间频繁的分页(进出交换),从而提高程序效率。这种优化技术如图6(a)所示,将图像处理时间从45.2秒显著降低到31.5秒。

**编译优化。**我们发现直接在目标设备上编译模型可以显著提高编码延迟和解码吞吐量。这可以归因于编译与目标设备指令集架构之间的更好一致性。如图6所示,这种优化尝试取得了有希望的结果。编码延迟从50.5秒显著降低到17.0秒,而解码吞吐量从1.3个token/秒显著提高到3.2个token/秒。

**配置优化。**我们观察到,llama.cpp框架的单一默认配置可能对不同的端侧设备并不最优。为了最大化推理速度,我们设计了一个自动参数搜索算法,动态确定最合适的配置(例如,在不同CPU核心上的计算分配)。通过配置优化,我们可以取得很好的改进。具体来说,解码吞吐量从3.2个token/秒激增到8.2个token/秒,超过了典型的人类阅读速度。





Figure 7: Results on different end-side devices. We show the (a) encoding latency and (b) decoding throughput across different device types. Xiaomi 14 Pro is the only device with NPU.

登录即可查看 [超5亿](#) 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



**NPU加速。**上述技术主要是为CPU部署量身定制的。另一个有希望的途径是利用其他类型的芯片,如GPU和NPU。尽管GPU有潜力,但我们在实验中发现,当前的移动电话GPU框架并没有优化或兼容到足以超过CPU的结果。作为替代方案,我们转向NPU(神经处理单元),这是近年来引入的一种新型专用硬件,专门设计用于加速AI应用。一些智能手机已经配备了NPU,被认为更适合解决计算瓶颈。

在实践中,我们主要利用NPU加速视觉编码。具体来说,我们将ViT的后端框架替换为QNN,同时保留llama.cpp后端用于LLM组件。对于配备高通NPU的移动电话,这种优化显著减少了视觉编码时间,从3.7秒降低到1.3秒,如图6(a)所示。

## 5.4 - 结果

**分析。**为了全面评估MiniCPM-Llama3-V 2.5在各种端侧设备上的性能,我们在图7中展示了小米14 Pro(Snapdragon 8 Gen 3)、vivo X00 Pro(Mediatek Dimensity 9300)和Macbook Pro(M1)上的测试结果。由于部署优化技术,MiniCPM-Llama3-V 2.5可以在移动电话和个人计算机上有效运行,提供可接受的延迟和吞吐量。例如,利用小米14 Pro上的NPU使其实现了与Mac M1相似的编码速度。此外,几乎所有设备都展现出与人类阅读速度相当或更高的吞吐量。

**讨论。**分析图7后,很明显,当前的计算瓶颈主要来自LLM预填充,这主要涉及编码图像和文本标记以供LLM推理。有前景的研究方向包括开发更有效的视觉编码方法,减少视觉标记数量,以及更好地利用GPU/NPU加速LLM编码。随着对端侧MLLM的日益关注和GPU/NPU加速技术的快速发展,我们相信端侧MLLM的实时交互很快就能实现。

## 6 - 实验

在这一部分中,我们对MiniCPM-V系列进行了全面评估。

### 6.1 - MiniCPM-V系列

我们发布了3个MiniCPM-V系列模型,包括MiniCPM-V 1.0、MiniCPM-V 2.0和MiniCPM-Llama3-V 2.5。如表3所示,MiniCPM-V 1.0使用预训练阶段1-2和SFT进行训练,没有使用自适应视觉编码和RLAIF-V。对于MiniCPM-V 2.0,我们包括了所有的训练阶段和自适应视觉编码策略,以进一步提高性能。在MiniCPM-Llama3-V 2.5中,Llama3-Instruct 8B被采用作为基础LLM。


Table 3: The MiniCPM-V series, with key components and configurations. AR.: aspect ratio.

| Model                | Base LLM           | Resolution                     | AR.   | Pre-training | SFT     | Alignment |
|----------------------|--------------------|--------------------------------|-------|--------------|---------|-----------|
| MiniCPM-V 1.0        | MiniCPM 2B         | 0.2M pixel (i.e., 448 × 448)   | Fixed | stage-1&2    | part1+2 | No        |
| MiniCPM-V 2.0        | MiniCPM 2B         | 1.8M pixel (e.g., 1344 × 1344) | Any   | stage-1&2&3  | part1+2 | RLAIF-V   |
| MiniCPM-Llama3-V 2.5 | Llama3-Instruct 8B | 1.8M pixel (e.g., 1344 × 1344) | Any   | stage-1&2&3  | part1+2 | RLAIF-V   |

表3:MiniCPM-V系列,关键组件和配置。AR.:纵横比。

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



| Model                      | Size | Open-Compass | MME           | MMB test (en) | MMB test (cn) | MMMU val    | Math-Vista  | LLaVA Bench | RW QA       | Obj HalBench (Res./Men.) ↓ |
|----------------------------|------|--------------|---------------|---------------|---------------|-------------|-------------|-------------|-------------|----------------------------|
| <b>Proprietary</b>         |      |              |               |               |               |             |             |             |             |                            |
| GPT-4V (2023.11.06)        | -    | 63.5         | 1771.5        | 77.0          | 74.4          | 53.8        | 47.8        | 93.1        | 63.0        | 13.6 / 7.3*                |
| Gemini Pro                 | -    | 62.9         | 2148.9        | 73.6          | 74.3          | 48.9        | 45.8        | 79.9        | 60.4        | -                          |
| Claude 3 Opus              | -    | 57.7         | 1586.8        | 63.3          | 59.2          | 54.9        | 45.8        | 73.9        | 48.4        | -                          |
| <b>Open-source</b>         |      |              |               |               |               |             |             |             |             |                            |
| DeepSeek-VL-1.3B           | 1.7B | 46.2         | 1531.6        | 66.4          | 62.9          | 33.8        | 29.4        | 51.1        | 49.7        | 16.7 / 9.6*                |
| Mini-Gemini                | 2.2B | -            | 1653.0        | -             | -             | 31.7        | -           | -           | -           | -                          |
| Yi-VL-6B                   | 6.7B | 48.9         | 1915.1        | 68.4          | 66.6          | 40.3        | 28.8        | 51.9        | 53.5        | 19.4 / 11.7*               |
| Qwen-VL-Chat               | 9.6B | 51.6         | 1860.0        | 61.8          | 56.3          | 37.0        | 33.8        | 67.7        | 49.3        | 43.8 / 20.0*               |
| Yi-VL-34B                  | 34B  | 52.2         | <b>2050.2</b> | 72.4          | 70.7          | 45.1        | 30.7        | 62.3        | 54.8        | 20.7 / 14.0*               |
| Phi-3-vision-128k-instruct | 4.2B | -            | -             | -             | -             | 40.4        | 44.5        | 64.2*       | 58.8*       | -                          |
| XTuner-Llama-3-8B-v1.1     | 8.4B | 53.3         | 1818.0        | 71.7          | 63.2          | 39.2        | 40.0        | 69.2        | -           | -                          |
| CogVLM-Chat                | 17B  | 54.2         | 1736.6        | 65.8          | 55.9          | 37.3        | 34.7        | 73.9        | 60.3        | 26.4 / 12.6*               |
| Bunny-Llama-3-8B           | 8.4B | 54.3         | 1920.3        | 77.0          | 73.9          | 41.3        | 31.5        | 61.2        | 58.8        | -                          |
| DeepSeek-VL-7B             | 7.3B | 54.6         | 1765.4        | 73.8          | 71.4          | 38.3        | 36.8        | 77.8        | 54.2        | 11.4 / 6.5*                |
| LLaVA-NeXT-Llama3-8B       | 8.4B | -            | 1971.5        | -             | -             | 41.7        | -           | 80.1        | 60.0        | -                          |
| Idedics2                   | 8.0B | 57.2         | 1847.6        | 75.7          | 68.6          | 45.2        | 52.2        | 49.1        | 60.7        | -                          |
| Cambrian-8B                | 8.3B | 58.8         | 1802.9        | 74.6          | 67.9          | 41.8        | 47.0        | 71.0        | 60.0        | -                          |
| CogVLM2-19B-Chat           | 19B  | 62.3         | 1869.5        | 73.9          | 69.8          | 42.6        | 38.6        | 83.0        | 62.9        | -                          |
| LLaVA-NeXT-Yi-34B          | 34B  | 62.7         | 2006.5        | <b>81.1</b>   | 79.0          | 48.8        | 40.4        | 81.8        | 66.0        | -                          |
| Cambrian-34B               | 34B  | 64.9         | 2049.9        | 80.4          | <b>79.2</b>   | <b>50.4</b> | 50.3        | 82.0        | <b>67.1</b> | -                          |
| MiniCPM-V 1.0              | 2.8B | 47.5         | 1650.2        | 64.1          | 62.6          | 38.3        | 28.9        | 51.3        | 51.2        | 21.6 / 11.5                |
| MiniCPM-V 2.0              | 2.8B | 54.5         | 1808.6        | 69.1          | 66.5          | 38.2        | 38.7        | <b>69.2</b> | <b>65.8</b> | <b>14.5 / 7.8</b>          |
| MiniCPM-Llama3-V 2.5       | 8.5B | <b>65.1</b>  | 2024.6        | 77.2          | 74.2          | 45.8        | <b>54.3</b> | <b>86.7</b> | 63.5        | <b>10.3 / 5.0</b>          |

表4:在通用多模态基准测试上的实验结果。RW QA:真实世界QA,Obj HalBench(Res./Men.):响应/提及级别的物体幻觉率,\*:我们使用官方检查点测试的结果。突出显示了最好的开源结果。

## 6.2 - 实验设置

**基准测试。**我们在流行的基准测试上进行全面评估,涵盖视觉问题回答、多模态对话、知识与推理、OCR和幻觉。(1)通用基准测试。我们采用OpenCompass [26]作为通用评估指标,这是一个涵盖11个流行多模态基准的全面集合,包括MME [33]、MMBench [63]、MMMU [113]、MathVista [71]、LLaVA Bench [62]等。我们还报告了RealWorldQA的真实世界空间理解能力的结果。(2)OCR基准测试。我们采用三个广泛使用的OCR能力评估基准测试,包括OCRBench [64]、TextVQA [91]和DocVQA [74]。(3)幻觉基准测试。我们还包括Object HalBench [85, 111]来评估模型的可信度。


**基线。**我们与不同系列中的强基线进行比较:对于开源模型,我们与包括Yi-VL-6B/34B [108]、Qwen-VL-Chat [7]、DeepSeek-VL7B [68]、TextMonkey [65]、CogVLM-Chat-17B [102]、CogVLM2-Llama3-19B [102]、Idedics28B [52]、Bunny-Llama-3-8B [39]、XTuner-Llama-3-8B-v1.1 [27]、LLaVA-NeXT-Llama-3-8B [53]、Cambrian-8B/34B [99]、LLaVA-NeXT-Yi-34B [61]、DeepSeek-VL-1.3B [68]、MobileVLM V2 [25]、Mini-Gemini [57]和Phi-3-Vision-128k-instruct [1]在内的强模型进行比较。对于专有模型,我们与GPT-4V-1106 [2]、Gemini-Pro [83]和Claude 3 Opus [5]进行比较。

## 6.3 - 实验结果

**通用多模态基准的主要结果。**从表4中的实验结果来看,我们有以下观察:(1) MiniCPM-Llama3-V 2.5以显著的优势超过了其他开源模型。例如,MiniCPM-Llama3-V 2.5在OpenCompass基准测试上超过了最近的强Idedics2-8B 7.9个百分点,两者的模型大小相似。它还取得了比Cambrian-34B、LLaVA-NeXT-Yi-34B、Yi-VL-34B和CogVLM2-Llama3-19B等明显更大的模型更好的结果。(2) 与功能强大的专有模型相比,如GPT-4V1106和Gemini Pro,MiniCPM-Llama3-V 2.5在OpenCompass基准测试上以明显更少的参数实现了更好的性能。此外,MiniCPM-Llama3-V 2.5在Object HalBench上还实现了比GPT-4V-1106更低的幻觉率,表明其在现实世界应用中的可信度。(3) 较小的2B参数MiniCPM-V 2.0的性能明显优于其他2B~3B模型,甚至与基于Llama3的8B MLLM如Bunny-Llama-3-8B相当。总之,结果表明MiniCPM-V系列在性能和效率之间实现了良好的平衡,使其更适合更广泛的社区和应用。

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



| Model                      | Size  | OCRBench | TextVQA val | DocVQA test |
|----------------------------|-------|----------|-------------|-------------|
| <b>Proprietary</b>         |       |          |             |             |
| Gemini Pro                 | -     | 680      | 74.6        | 88.1        |
| GPT-4V (2023.11.06)        | -     | 645      | 78.0        | 88.4        |
| <b>Open-source</b>         |       |          |             |             |
| Yi-VL-6B                   | 6.7B  | 290      | 45.5*       | 17.1*       |
| Yi-VL-34B                  | 34B   | 290      | 43.4*       | 16.9*       |
| Mini-Gemini                | 2.2B  | -        | 56.2        | 34.2*       |
| MobileVLM V2               | 3.1B  | -        | 57.5        | 19.4*       |
| DeepSeek-VL-1.3B           | 1.7B  | 413      | 58.4*       | 37.9*       |
| Qwen-VL-Chat               | 9.6B  | 488      | 61.5        | 62.6        |
| DeepSeek-VL-7B             | 7.3B  | 435      | 64.7*       | 47.0*       |
| CogVLM-Chat                | 17.4B | 590      | 70.4        | 33.3*       |
| TextMonkey                 | 9.7B  | 558      | 64.3        | 66.7        |
| Idefics2                   | 8.0B  | -        | 73.0        | 74.0        |
| Phi-3-vision-128k-instruct | 4.2B  | 639*     | 70.9        | -           |
| MiniCPM-V 1.0              | 2.8B  | 366      | 60.6        | 38.2        |
| MiniCPM-V 2.0              | 2.8B  | 605      | 74.1        | 74.9        |
| MiniCPM-Llama3-V 2.5       | 8.5B  | 725      | 76.6        | 84.8        |

公众号·旺知识

**OCR基准测试的结果。**MiniCPM-V模型在包括场景文本、文档和截图理解在内的OCR能力方面也表现出色。如表5所示,MiniCPM-Llama3-V 2.5在OCRBench、TextVQA和DocVQA上超过了1.7B~34B范围内的开源MLLM,甚至与GPT-4V-1106和Gemini Pro等专有模型表现相当。

**多语言多模态能力。**基于VisCPM的多语言多模态泛化方法,MiniCPM-Llama3-V 2.5将其多模态能力扩展到30多种语言。如图8所示,MiniCPM-Llama3-V 2.5可以在多语言LLaVA Bench上胜过Yi-VL 34B和Phi-3-vision-128k-instruct。这种有前途的多语言多模态能力使MiniCPM-Llama3-V 2.5对使用各种语言的更大群体有用。




Figure 8: Experimental results on multilingual multimodal interaction. We translate LLaVA Bench reference response into different languages, and adopt GPT-4-Turbo for evaluation. Here we randomly select 15 languages for visualization.

**与其他基于Llama-3的模型的比较。**从表4的实验结果来看,我们可以观察到:(1) MiniCPM-Llama3-V 2.5以很大的优势超过了其他基于Llama-3的模型。例如,与强大的LLaVA-NeXT-Llama-3-8B相比,MiniCPM-Llama3-V 2.5在所有基准测试上都取得了更好的结果。(2) 值得注意的是,MiniCPM-Llama3-V 2.5的推理计算需求显著减少。例如,MiniCPM-Llama3-V 2.5的视觉标记数量范围是(96, 960),低于LLaVA-NeXT Llama-3-8B的(1728, 2880)。这对于实际的端侧应用来说可能很重要,因为它涉及到推理速度、首标记延迟、内存使用和功耗等方面。


#### 6.4 - 消融研究

我们对MiniCPM-Llama3-V 2.5的组件进行了消融研究,包括RLAIF-V和多语言训练。

**RLAIF-V的影响。**从表6的结果来看,我们可以观察到RLAIF-V有效地降低了基础模型在响度和提及级别的幻觉率。这使得模型在行为上更加可信。重要的是,降低幻觉率并没有牺牲模型的一般能力。相反,RLAIF-V平均在11个基准测试上的OpenCompass上进一步提高了整能0.6个百分点。

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。



| Method       | Compass | MIME   | dev(en) | dev(zh) | val  | Vista | Bench | HalBench    |
|--------------|---------|--------|---------|---------|------|-------|-------|-------------|
| w/o RLAIIF-V | 64.5    | 2039.8 | 77.7    | 73.5    | 46.2 | 54.1  | 85.4  | 86.9 / 93.6 |
| w RLAIIF-V   | 65.1    | 2024.6 | 77.2    | 74.2    | 45.8 | 54.3  | 86.7  | 89.7 / 95.0 |

多语言泛化。我们研究了多语言泛化技术的必要性和有效性。如表8所示,我们可以看到在使用不到0.5%的多语言SFT数据时,所有语言的性能都提高了25分以上。结果表明,多语言泛化方法可以有效地提高多语言能力,同时具有良好的数据和计算效率。此外,我们注意到不同语言的性能提升是不均匀的。我们假设改进程度可能与多种因素有关,如基础LLM对给定语言的能力。我们将更系统的探索留待未来的工作。

Table 7: The influence of multilingual generalization. We use 90k multilingual data (< 0.5% SFT data) for post SFT training, and show the performance changes below. ML: multilingual training.

| Method | French | German | Portuguese | Spanish | Czech | Hungarian | Japanese | Korean | Thai |
|--------|--------|--------|------------|---------|-------|-----------|----------|--------|------|
| w/o ML | 46.4   | 22.8   | 53.0       | 29.0    | 26.5  | 20.6      | 13.8     | 13.7   | 14.4 |
| w ML   | 72.7   | 76.5   | 83.8       | 73.9    | 71.6  | 70.9      | 88.0     | 67.9   | 61.9 |

6.5 - 案例研究

我们通过案例研究更直观地展示了MiniCPM-Llama3-V 2.5的能力。

OCR能力。MiniCPM-Llama3-V 2.5在现实场景中展示了强大的OCR能力。如图2所示,该模型能够准确地将屏幕截图中的英文文章转录成纯文本,将包含中英文内容的表格转换为Markdown格式,理解代码逻辑,并根据图像内容提供合理的计划。

任何纵横比的高分辨率输入。MiniCPM-Llama3-V 2.5的一个显著特点是其能够处理具有极端纵横比的高分辨率输入。如图9所示,该模型很好地处理了纵横比为10:1的输入,准确识别了细粒度的文章内容。有趣的是,该模型还可以解释图像中的图像,正确地描述了中央图像中的男子"微笑并拿着巧克力慕斯"。




Figure 9: The example of MiniCPM-Llama3-V 2.5 for the input image with extreme aspect ratio.

多语言多模态能力。得益于VisCPM的多语言多模态泛化方法,MiniCPM-Llama3-V 2.5展现了多语言能力,泛化到30多种语言。图11展示了对在德语、法语、日语、韩语和西班牙语中的多模态对话,显示了对特定语言文化的了解。

登录即可查看 超5亿 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。






Figure 10: Comparison between MiniCPM-Llama3-V 2.5 and GPT-4V on hallucinations.

可信行为。基于RLAIF-V,MiniCPM-Llama3-V 2.5确保了更可信的响应,具有更低的幻觉率。如图10所示,与功能强大的GPT-4V相比,该模型的响应显示出更少的幻觉,展示了其在现实场景中的可靠性和可信度。

## 7 - 结论

**贡献。**在这项工作中,我们介绍了MiniCPM-V系列模型,作为对强大的端侧多模态大型语言模型(MLLM)的初步探索。得益于自适应视觉编码、多语言泛化和RLAIF-V方法等技术,MiniCPM-Llama3-V 2.5能够在参数数量大大减少的情况下实现与GPT-4V相当的性能水平。通过各种端侧优化技术,该模型确保了在手机上的可接受用户体验。


**局限性。**尽管表现出了有希望的性能,但当前的MiniCPM-V模型仍然存在一些局限性。(1)能力深度。在增强多模态理解能力和推理效率方面,仍有很大的改进空间。(2)能力广度。除了图像模态外,扩展MLLM能力以包含其他模态,如视频和音频等,是有前景的方向,GPT-4o[78]和Google Astra[29]已经给出了很好的例子。


除了MLLM能力外,端侧部署也带来了独特的挑战。推理速度和延迟还远远不够好,模型服务可能受到电池容量的限制。此外,以前的芯片和部署框架主要针对CNN和LSTM,这些对MLLM来说可能是次优的。针对MLLM量身定制的努力可以带来很大的改进空间。

**未来工作。**考虑到当前的局限性和端侧MLLM的有希望的未来,我们预计学术界和工业界将增加努力,提高模型在深度和广度方面的能力,并改善智能手机芯片和部署框架。我们相信,模型能力和端侧设备容量的同步进步将很快带来端侧应用,为用户提供令人满意的体验。

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。





作者：张长旺，图源：旺知识

#### 参考资料

标题：MiniCPM-V: A GPT-4V Level MLLM on Your Phone

作者：Yuan Yao, Tianyu Yu, Ao Zhang, Chongyi Wang, Junbo Cui, Hongji Zhu, Tianchi Cai, Haoyu Li, Weilin Zhao, Zhihui He, Qianyu Chen, Huarong Zhou, Zhensheng Zou, Haoye Zhang, Shengding Hu, Zhi Zheng, Jie Zhou, Jie Cai, Xu Han, Guoyang Zeng, Dahai Li, Zhiyuan Liu, Maosong Sun

单位：MiniCPM-V Team, OpenBMB

标签：人工智能、多模态学习、大型语言模型、端侧部署、移动设备

概述：MiniCPM-V是一项突破性研究，成功开发了一款能在智能手机上运行的、性能匹敌GPT-4V的多模态大型语言模型(MLLM)。

链接：[arxiv.org/abs/2408.0180...](https://arxiv.org/abs/2408.0180...)

发布于 2024-08-11 18:40 · 广东

[多模态大模型](#) [端侧大模型](#) [LLM（大型语言模型）](#)

▲ 赞同 3 ▼ ● 添加评论 ↻ 分享 ❤ 喜欢 ★ 收藏 📄 申请转载 ...

写下你的评论...

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。





还没有评论，发表第一个评论吧

## 推荐阅读

### 关于分布式CAP理论 Raft协议的种种

Raft协议 raft数据同步流程(强烈推荐) raft 协议可视化:  
<http://thesecretlivesofdata.com/raft>  
<https://raft.github.io/>客户端推送数据数据 append 到leader的log中.数据从leader通过 app...

Josef...

发表于PityC...



### AIDD论文详解：ESM3(一) —— 输入构建

好几天没上课

### TVM之TIR相关数据结构

TVM 会将前端框架的模型转化成 Relay IR，基于Relay IR会进行一些优化pass。然后转化成基于Tensor的表达，并在Tensor 表达的基础上添加schedule 调度。最后会 lowering成TIR 并做codegen处理...

sunny...

发表于TVM 源...

| Feature vector x |   |   |     |    |    |    |    |     |     |     |     |     |
|------------------|---|---|-----|----|----|----|----|-----|-----|-----|-----|-----|
| 1                | 0 | 0 | ... | 1  | 0  | 0  | 0  | ... | 0.3 | 0.3 | 0.3 | 0   |
| 1                | 0 | 0 | ... | 0  | 1  | 0  | 0  | ... | 0.3 | 0.3 | 0.3 | 0   |
| 1                | 0 | 0 | ... | 0  | 0  | 1  | 0  | ... | 0.3 | 0.3 | 0.3 | 0   |
| 0                | 1 | 0 | ... | 0  | 0  | 1  | 0  | ... | 0   | 0   | 0.5 | 0.5 |
| 0                | 1 | 0 | ... | 0  | 0  | 0  | 1  | ... | 0   | 0   | 0.5 | 0.5 |
| 0                | 0 | 1 | ... | 1  | 0  | 0  | 0  | ... | 0.5 | 0   | 0.5 | 0   |
| 0                | 0 | 1 | ... | 0  | 0  | 1  | 0  | ... | 0.5 | 0   | 0.5 | 0   |
| A                | B | C | ... | T1 | NH | DW | ST | ... | T1  | NH  | DW  | ST  |
| 13               | 0 | 0 | ... | 14 | 1  | 0  | 0  | ... | 16  | 0   | 0   | 0   |
| 5                | 0 | 0 | ... | 8  | 0  | 0  | 0  | ... | 9   | 0   | 0   | 0   |
| 12               | 1 | 0 | ... | 12 | 1  | 0  | 0  | ... | 12  | 1   | 0   | 0   |
| User             |   |   |     |    |    |    |    |     |     |     |     |     |
| Movie            |   |   |     |    |    |    |    |     |     |     |     |     |
| Color features   |   |   |     |    |    |    |    |     |     |     |     |     |
| T1               |   |   |     |    |    |    |    |     |     |     |     |     |
| T2               |   |   |     |    |    |    |    |     |     |     |     |     |

### 最小推荐系统: Factorization Machines(FM)

OwlLi...

发表于

登录即可查看 **超5亿** 专业优质内容

超 5 千万创作者的优质提问、专业回答、深度文章和精彩视频尽在知乎。

