



(12) 发明专利申请

(10) 申请公布号 CN 118229700 A

(43) 申请公布日 2024. 06. 21

(21) 申请号 202410645393.5

(22) 申请日 2024.05.23

(71) 申请人 厦门大学

地址 361000 福建省厦门市思明南路422号

(72) 发明人 曹刘娟 纪荣嵘 张声传 黄有

(74) 专利代理机构 厦门市新华专利商标代理有限公司 35203

专利代理师 渠述华

(51) Int. Cl.

G06T 7/10 (2017.01)

G06T 9/00 (2006.01)


权利要求书2页 说明书6页 附图1页

(54) 发明名称

实时的交互式图像分割方法

(57) 摘要

本发明公开一种实时的交互式图像分割方法,涉及计算机视觉技术领域,引入了一种创新的处理交互分割问题的流程,能够提高交互式分割任务的计算效率,包括:步骤1、使用大型视觉模型对图像进行并行预处理,得到图像特征;步骤2、通过一轻量级的交互式分割模块,实时处理图像特征和用户输入的交互信息,能够从图像中准确地分割出目标区域,并根据用户的反馈不断提高分割的准确度。本发明通过将来自大型视觉模型预处理的图像特征与用户输入的交互信息相结合,并使用单一的轻量级交互式分割模块执行交互式分割,这种设计不仅保持了模型分割性能的竞争力,同时也优化了模型推理流程,显著提高了计算效率,为实时交互式图像分割提供了有效的解决方案。



1. 一种实时的交互式图像分割方法,其特征在于包括以下步骤:

步骤1、对图像进行并行预处理,利用预训练的大型视觉模型对图像特征进行编码,得到图像特征 $F \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$;其中 R 为实数空间, H 和 W 分别为图像的高和宽;

步骤2、使用轻量级的交互式分割模块,实时处理图像特征 F 和用户输入的交互信息,用户输入的交互信息包括点击信息和编码信息;

步骤2-1、通过编码器将用户输入的 N 个点击信息转换为点击编码 $C \in R^{N \times 256}$ 、掩码信息转换为掩码编码 $E \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$,得到包含点击编码 C 和掩码编码 E 的交互编码,每次用户通过点击进行交互时都对交互编码进行更新;

步骤2-2、将交互编码与可学习的Query编码 $q \in R^{1 \times 256}$ 送入SAM的解码器中,并与图像特征 F 结合,通过公式 $q_c, F_c = \text{Decoder}(E, F, C, q)$ 将交互编码融合转化为融合交互信息的Query编码 $q_c \in R^{1 \times 256}$ 与融合交互信息的上采样图像特征 $F_c \in R^{\frac{H}{4} \times \frac{W}{4} \times 256}$;

步骤2-3、通过公式 $F_c \cdot q_c^T = M$,使用点乘将融合交互信息的上采样图像特征 F_c 与融合交互信息的Query编码 q_c 进一步融合,得到预测掩码 $M \in R^{\frac{H}{4} \times \frac{W}{4} \times 1}$;其中 q_c^T 为 q_c 的转置;

步骤2-4、在用户进行预定义的第 K 次交互时,大型视觉模型通过公式 $\text{FocusRefiner}(F, q_c^{(K-1)}, M^{(K-1)}) = F_r^{(K)}$,以图像特征 F 、第 $K-1$ 次的融合交互信息的Query编码 $q_c^{(K-1)}$ 与第 $K-1$ 次的预测掩码 $M^{(K-1)}$ 为输入,得到聚焦于目标物体的优化图像特征 $F_r^{(K)}$,优化图像特征 $F_r^{(K)}$ 在后续的针对同一物体的分割流程中代替图像特征 F ;

步骤2-5、通过公式 $\bar{F} = \text{Windowfy}(F^b)$,使用两种具有不同窗口结构的图像窗口化方法交替地对MSA模块的一个Batch的输入 $F^b \in R^{B \times \frac{H}{16} \times \frac{W}{16} \times 256}$ 进行预处理,预定义窗口的尺寸 S ,得到变换后的图像特征 $\bar{F} \in R^{L \times S \times S \times 256}$,其中 $L = B \cdot H \cdot W / (16S)^2$,其中 B 为图像的数量,并从变换后的图像特征 $\bar{F}$ 中选出包含物体的窗口得到待处理的图像特征 $f \in R^{S \times S \times 256}$,进行MSA计算 $q_f = \text{Attention}(q_c, f, f)$ 和 $\hat{f} = \text{Attention}(f, f, f)$;其中 q_f 为经MSA计算后的融合交互信息的Query编码, Attention 为Transformer中的注意力算子, $\hat{f}$ 为包含物体的自注意力图;

步骤2-6、引入动态ReLU作为激活函数,得到与交互信息融合的动态激活结果 $\hat{f}_q = \text{PDyReLU}(\hat{f}; q_f)$,MSA模块输出 q_f 和 f_q 作为下一个FocusRefiner模块的输入,即 $f_q = f + \text{DeformConv}(f + \hat{f}_q)$;

步骤2-7、经过FocusRefiner模块和SAM的解码器得到最终的图像编码 F'_c 与最终的

Query编码 q'_c ,并通过点乘得到最终的预测掩码 M' ;将最终的预测掩码与标签计算的Normalized Focal Loss和Point Loss作为神经网络的损失函数,即 $PTL(M', \{(x_i, y_i, z_i)\}) = \sum_i (M'(x_i, y_i) - z_i)^2$,其中 $PTL(\cdot)$ 为损失函数, $M'(\cdot)$ 表示遍历 M' 的每个元素;

步骤2-8、在训练以及标准测试的流程中,根据最终的预测掩码与掩码标签,寻找误差最大的连通区域,选择该连通区域的中心像素作为模拟的下一次点击的位置,迭代进行下一次的模型预测;在真实测试环境中,则根据用户的交互点击反馈进行迭代预测,逐步提高分割质量。

2.如权利要求1所述的实时的交互式图像分割方法,其特征在于:

所述步骤1中,所述大型视觉模型是Vision Transformer。

3.如权利要求1所述的实时的交互式图像分割方法,其特征在于:

所述步骤2-2中,所述解码器通过交叉注意力机制融合 $[q; c] \in R^{(N+1) \times 256}$ 与 $(F + E) \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$,即 $Decoder(E, F, c, q) = CrossAttn([q; c], F + E)$ 。

实时的交互式图像分割方法

技术领域

[0001] 本发明涉及计算机视觉技术领域,特别是指一种实时的交互式图像分割方法。

背景技术

[0002] 在海量数据的推动下,深度网络在各种计算机视觉任务中获得引人注目的成绩。准确标注数据的可用性对于深度网络的成功至关重要,然而手动标注的过程会占用大量的时间和计算资源。因此,逐步发展起来的交互式图像分割已经成为标注大规模图像数据集不可或缺的工具。这种技术旨在通过有限的交互实现高质量的像素级标注,交互方式包括涂鸦、边界框、多边形、点击或一些上述方法的组合。在众多交互式图像分割方法中,基于点击的方法因其简单高效而备受关注。因此,本发明专注于基于点击的方法,并尝试解决其在实际应用中的计算和效率问题。

[0003] 近期关于点击的交互式分割方向的研究集中在实时、高质量的交互式分割表现,如SAM(Alexander Kirillov, Eric Mintun, Nikhila Ravi, Hanzi Mao,646Chloe Rolland, Laura Gustafson, Tete Xiao, Spencer White-647head, Alexander C. Berg, Wan-Yen Lo, Piotr Doll'ar, and648Ross Girshick. Segment anything. arXiv:2304.02643, 2023.)、InterFormer(You Huang, Hao Yang, Ke Sun, Shengchuan Zhang, Liu- 624juan Cao, Guannan Jiang, and Rongrong Ji. Interformer: 625Real-time interactive image segmentation. In Proceedings 626of the IEEE/CVF International Conference on Computer Vi- 627sion, pages 22301-22311, 2023)等。然而,实时的交互流程存在两个限制:

(1) 首先,该流程的图像预处理禁用了在交互过程中动态重聚焦模型至目标对象的图像级放大策略的高效实现;

(2) 其次,由于需要实时响应,SAM的轻量级解码器难以充分融合交互信息与预处理的图像嵌入,从而削弱了交互反馈对分割质量的正面影响。

[0004] 因此,SAM在面对如伪装对象几乎与背景融为一体的挑战性场景时常遇到分割结果不够稳定的问题,例如在足够次数的点击提示后新增一个点击仍会偶然性地触发分割质量的显著降低,如IoU从88.59下降到12.78。这种不稳定性显著限制了SAM在更广泛的图像分割注释中的适用性。这两个问题共同导致计算效率低下。为提高交互式分割的计算效率,需要解决这些潜在问题。

发明内容

[0005] 本发明的目的在于提供一种实时的交互式图像分割方法,解决现有技术中存在的问题,提高交互式分割的计算效率和分割质量,能够实现在低功耗的设备上实时地进行高质量的交互式分割,解决现有交互式图像分割流程的效率问题,并为大模型在交互分割领域的应用提供可行路径。

[0006] 为了达成上述目的,本发明的解决方案是:

一种实时的交互式图像分割方法,包括以下步骤:

步骤1、对图像进行并行预处理,利用预训练的大型视觉模型对图像特征进行编码,得到图像特征 $F \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$;其中 R 为实数空间, H 和 W 分别为图像的高和宽;

步骤2、使用轻量级的交互式分割模块,实时处理图像特征 F 和用户输入的交互信息,用户输入的交互信息包括点击信息和编码信息;

步骤2-1、通过编码器将用户输入的 N 个点击信息转换为点击编码 $C \in R^{N \times 256}$ 、掩码信息转换为掩码编码 $E \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$,得到包含点击编码 C 和掩码编码 E 的交互编码,每次用户通过点击进行交互时都对交互编码进行更新;

步骤2-2、将交互编码与可学习的Query编码 $q \in R^{1 \times 256}$ 送入SAM的解码器中,并与图像特征 F 结合,通过公式 $q_c, F_c = \text{Decoder}(E, F, C, q)$ 将交互编码融合转化为融合交互信息的Query编码 $q_c \in R^{1 \times 256}$ 与融合交互信息的上采样图像特征 $F_c \in R^{\frac{H}{4} \times \frac{W}{4} \times 256}$;

步骤2-3、通过公式 $F_c \cdot q_c^T = M$,使用点乘将融合交互信息的上采样图像特征 F_c 与融合交互信息的Query编码 q_c 进一步融合,得到预测掩码 $M \in R^{\frac{H}{4} \times \frac{W}{4} \times 1}$;其中 q_c^T 为 q_c 的转置;

步骤2-4、在用户进行预定义的第 K 次交互时,大型视觉模型通过公式 $\text{FocusRefiner}(F, q_c^{(K-1)}, M^{(K-1)}) = F_r^{(K)}$,以图像特征 F 、第 $K-1$ 次的融合交互信息的Query编码 $q_c^{(K-1)}$ 与第 $K-1$ 次的预测掩码 $M^{(K-1)}$ 为输入,得到聚焦于目标物体的优化图像特征 $F_r^{(K)}$,优化图像特征 $F_r^{(K)}$ 在后续的针对同一物体的分割流程中代替图像特征 F ;

步骤2-5、通过公式 $\bar{F} = \text{Windowfy}(F^b)$,使用两种具有不同窗口结构的图像窗口化方法交替地对MSA模块的一个Batch的输入 $F^b \in R^{B \times \frac{H}{16} \times \frac{W}{16} \times 256}$ 进行预处理,预定义窗口的尺寸 S ,得到变换后的图像特征 $\bar{F} \in R^{L \times S \times S \times 256}$,其中 $L = B \cdot H \cdot W / (16S)^2$,其中 B 为图像的数量,并从变换后的图像特征 $\bar{F}$ 中选出包含物体的窗口得到待处理的图像特征 $f \in R^{S \times S \times 256}$,进行MSA计算 $q_f = \text{Attention}(q_c, f, f)$ 和 $\hat{f} = \text{Attention}(f, f, f)$;其中 q_f 为经MSA计算后的融合交互信息的Query编码, Attention 为Transformer中的注意力算子, $\hat{f}$ 为包含物体的自注意力图;

步骤2-6、引入动态ReLU作为激活函数,得到与交互信息融合的动态激活结果 $\hat{f}_q = \text{PDyReLU}(\hat{f}; q_f)$,MSA模块输出 q_f 和 f_q 作为下一个FocusRefiner模块的输入,即 $f_q = f + \text{DeformConv}(f + \hat{f}_q)$;

步骤2-7、经过FocusRefiner模块和SAM的解码器得到最终的图像编码 F'_c 与最终的

Query编码 q'_c ,并通过点乘得到最终的预测掩码 M' ;将最终的预测掩码与标签计算的Normalized Focal Loss和Point Loss作为神经网络的损失函数,即 $PTL(M', \{(x_i, y_i, z_i)\}) = \sum_i (M'(x_i, y_i) - z_i)^2$,其中 $PTL(\cdot)$ 为损失函数, $M'(\cdot)$ 表示遍历 M' 的每个元素;

步骤2-8、在训练以及标准测试的流程中,根据最终的预测掩码与掩码标签,寻找误差最大的连通区域,选择该连通区域的中心像素作为模拟的下一次点击的位置,迭代进行下一次的模型预测;在真实测试环境中,则根据用户的交互点击反馈进行迭代预测,逐步提高分割质量。

[0007] 所述步骤1中,所述大型视觉模型是Vision Transformer。

[0008] 所述步骤2-2中,所述解码器通过交叉注意力机制融合 $[q; c] \in R^{(N+1) \times 256}$ 与 $(F + E) \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$,即 $Decoder(E, F, c, q) = CrossAttn([q; c], F + E)$ 。

[0009] 采用上述技术方案后,本发明具有以下技术效果:

①本发明通过将来自大型视觉模型预处理的图像特征与用户输入的交互信息(如点击)相结合,并使用单一的轻量级交互式分割模块执行交互式分割,这种设计不仅保持了模型分割性能的竞争力,同时也优化了模型推理流程,显著提高了计算效率,为实时交互式图像分割提供了一种有效的解决方案;

②本发明提出动态窗口多头自注意力模块,将图像嵌入分割成窗口,并根据之前预测的遮罩有选择性地对窗口嵌入的子集执行注意力计算;本发明还应用了移位策略以允许嵌入之间进行长距离信息交换而不牺牲效率,同时以增强图像嵌入为目的提出像素级别的动态ReLU,使用SAM解码器的点击融合查询嵌入来有选择性地增强与对象相关的图像嵌入,并以像素级方式抑制与对象无关的嵌入,从而展示比最近提出的方法更快的推理速度和更好的分割结果。

附图说明

[0010] 图1为本发明具体实施例神经网络的网络结构示意图;

图2为本发明具体实施例的实验数据表。

具体实施方式

[0011] 为了进一步解释本发明的技术方案,下面通过具体实施例来对本发明进行详细阐述。

[0012] 本发明提出一种实时的交互式图像分割方法,旨在提高交互式分割的计算效率。在交互过程之前,本发明利用大型视觉模型,例如在计算集群等高性能设备上运行的Vision Transformer(ViT)模型(Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In 9th International Conference on Learning

Representations, ICLR 2021, Virtual Event, Austria, May 3-7, 2021. OpenReview.net, 2021),从要标注的图像中提取高质量且可重复利用的图像特征。提取图像特征的步骤是离线完成的,因此不需要实时性能。接着,本发明使用一个轻量级的交互式分隔模块在个人电脑或移动设备等低功耗设备上执行交互式分割,该交互式分隔模块将由大型视觉模型提取的图像特征与标注者的点击作为输入。

[0013] 此外,本发明提出动态窗口多头自注意力模块,将图像嵌入分割成窗口,并根据之前预测的遮罩有选择性地对窗口嵌入的子集执行注意力计算;本发明还应用了移位策略以允许嵌入之间进行长距离信息交换而不牺牲效率,同时以增强图像嵌入为目的提出像素级别的动态ReLU,使用SAM解码器的点击融合查询嵌入来有选择性地增强与对象相关的图像嵌入,并以像素级方式抑制与对象无关的嵌入,从而展示比最近提出的方法更快的推理速度和更好的分割结果。总体而言,本发明在保持模型分割性能具有竞争力的同时,还实现了优化模型推理流程、提高计算效率。

[0014] 参考图1所示,本发明公开了一种实时的交互式图像分割方法,包括以下步骤:

步骤1、对图像进行并行预处理,利用预训练的大型视觉模型Vision Transformer对图像特征进行编码,得到图像特征 $F \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$;其中 R 为实数空间, H 和 W 分别为图像的高和宽;

步骤2、使用轻量级的交互式分割模块,实时处理图像特征 F 和用户输入的交互信息,用户输入的交互信息包括点击信息和编码信息;在预定义的第 K 次交互时,通过引入FocusRefiner模块将图像特征与 $K-1$ 次交互的分割结果融合,转换为聚焦目标物体的优化特征图;具体包括以下步骤:

步骤2-1、通过编码器将用户输入的 N 个点击信息转换为点击编码 $C \in R^{N \times 256}$ 、掩码信息转换为掩码编码 $E \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$,得到包含点击编码 C 和掩码编码 E 的交互编码,每次用户通过点击进行交互时都对交互编码进行更新;

步骤2-2、将交互编码与可学习的Query编码 $q \in R^{1 \times 256}$ 送入SAM的解码器中,并与图像特征 F 结合,通过公式 $q_c, F_c = \text{Decoder}(E, F, C, q)$ 将交互编码融合转化为融合交互信息的Query编码 $q_c \in R^{1 \times 256}$ 与融合交互信息的上采样图像特征 $F_c \in R^{\frac{H}{4} \times \frac{W}{4} \times 256}$;其中,解码器通过交叉注意力机制融合 $[q; c] \in R^{(N+1) \times 256}$ 与 $(F + E) \in R^{\frac{H}{16} \times \frac{W}{16} \times 256}$,即 $\text{Decoder}(E, F, C, q) = \text{CrossAttn}([q; c], F + E)$;

步骤2-3、通过公式 $F_c \cdot q_c^T = M$,使用点乘将融合交互信息的上采样图像特征 F_c 与融合交互信息的Query编码 q_c 进一步融合,得到预测掩码 $M \in R^{\frac{H}{4} \times \frac{W}{4} \times 1}$;其中 q_c^T 为 q_c 的转置;

步骤2-4、采用聚焦目标物体策略,引入FocusRefiner模块实现提高注意力模块的效率,该FocusRefiner模块在每个物体的分割过程中仅被调用一次,促使图像特征聚焦目标物体,以便获取足够的上下文信息;

具体而言,在用户进行预定义的第 K 次交互时,大型视觉模型通过公式 $\text{FocusRefiner}(F, q_c^{(K-1)}, M^{(K-1)}) = F_r^{(K)}$,以图像特征 F 、第 $K-1$ 次的融合交互信息的Query编码 $q_c^{(K-1)}$ 与第 $K-1$ 次的预测掩码 $M^{(K-1)}$ 为输入,得到聚焦于目标物体的优化图像特征 $F_r^{(K)}$,实现用户输入的交互信息与图像特征 F 的进一步融合,而优化图像特征 $F_r^{(K)}$ 在后续的针对同一物体的分割流程中代替图像特征 F ;

步骤2-5、为了进一步降低注意力模块的计算复杂度,在FocusRefiner模块中采用特殊的窗口策略——通过公式 $\bar{F} = \text{Windowfy}(F^b)$,使用两种具有不同窗口结构的图像窗口化方法交替地对MSA模块的一个Batch的输入 $F^b \in R^{B \times \frac{H}{16} \times \frac{W}{16} \times 256}$ 进行预处理,预定义窗口的尺寸 S (窗口尺寸为模型的结构参数,可以预先定义),得到变换后的图像特征 $\bar{F} \in R^{L \times S \times S \times 256}$,其中 $L = B \cdot H \cdot W / (16S)^2$, B 为图像的数量,并从变换后的图像特征 $\bar{F}$ 中选出包含物体的窗口得到待处理的图像特征 $f \in R^{S \times S \times 256}$,进行MSA计算 $q_f = \text{Attention}(q_c, f, f)$ 和 $\hat{f} = \text{Attention}(f, f, f)$;其中 q_f 为经MSA计算后的融合交互信息的Query编码, Attention 为Transformer中的注意力算子, $\hat{f}$ 为包含物体的自注意力图;

步骤2-6、为了进一步提高FocusRefiner模块的定位能力,实现引入像素级别的动态ReLU作为激活函数,得到与交互信息融合的动态激活结果 $\hat{f}_q = \text{PDyReLU}(\hat{f}; q_f)$,使得激活过程依赖于输入参数,能够充分利用物体相关编码的相似性;最终MSA模块输出 q_f 和 f_q 作为下一个FocusRefiner模块的输入,即 $f_q = f + \text{DeformConv}(f + \hat{f}_q)$;

步骤2-7、经过FocusRefiner模块和SAM的解码器得到最终的图像编码 F'_c 与最终的Query编码 q'_c ,并通过点乘得到最终的预测掩码 M' ;将最终的预测掩码与标签计算的Normalized Focal Loss和Point Loss作为神经网络的损失函数,即 $\text{PTL}(M', \{(x_i, y_i, z_i)\}) = \sum_i (M'(x_i, y_i) - z_i)^2$,其中 $\text{PTL}(\cdot)$ 为损失函数, $M'(\cdot)$ 表示遍历 M' 的每个元素;

步骤2-8、在训练以及标准测试的流程中,根据最终的预测掩码与掩码标签,寻找误差最大的连通区域,选择该连通区域的中心像素作为模拟的下一次点击的位置,迭代进行下一次的模型预测;在真实测试环境中,则根据用户的交互点击反馈进行迭代预测,逐步提高分割质量。

[0015] 通过上述方案,本发明具有以下突出的优点:

本发明通过将来自大型视觉模型预处理的图像特征与用户输入的交互信息(如点击)相结合,并使用单一的轻量级交互式分割模块执行交互式分割,这种设计不仅保持了模型分割性能的竞争力,同时也优化了模型推理流程,显著提高了计算效率,为实时交互式图

像分割提供了一种有效的解决方案。

[0016] 以下,通过仿真实验及其实验数据进一步说明本发明的技术效果。

[0017] 1) 仿真条件

本发明在Ubuntu平台上进行开发,开发的深度学习框架基于Pytorch,主要使用的语言为Python。

[0018] 2) 仿真内容

取COC02017以及LVIS数据集,根据以上的步骤训练网络并且使用GrabCut、Berkley、SBD、DAVIS、MVTec和COD10K作为测试集进行测试。参见图2,为本发明与其他方法在六个测试数据集的分割结果。经过直观的数值比较,可以发现相比于其他方法,本发明的效果最佳。其中,评价指标NoC (Number of Clicks) 表示的是达到一定的IoU阈值需要的点击次数,SPC (Seconds Per Click) 表示的是进行一次点击推理耗费的时间,衡量了模型在潜在的大或小的物体上的像素分割中的效率;通过NoC指标对比可以看到,本方法在分割质量上达到与其他最先进方法相匹配的效果,同时相比其他方法具有更低的SPC,即具有更小的计算负担和更高的推理效率。

[0019] 上述实施例和图式并非限定本发明的产品形态和式样,任何所属技术领域的普通技术人员对其所做的适当变化或修饰,皆应视为不脱离本发明的专利范畴。




图1

Method	↓SPC/s	GrabCut	Berkeley	SBD	DAVIS	MVTec	COD10K	Mean
f-BRS-B-HR32 _{CVPR20}	-	1.69	2.44	7.26	6.50	-	-	-
RITM-HR18s _{Preprint21}	-	1.68	2.60	6.48	5.98	-	-	-
RITM-HR32 _{Preprint21}	-	1.56	2.10	5.71	5.34	-	-	-
CDNet-R34 _{ICCV21}	-	1.52	2.06	7.04	5.56	-	-	-
EdgeFlow-HR18 _{ICCVW21}	-	1.72	2.40	-	5.77	-	-	-
PseudoClick-HR32 _{ECCV22}	-	1.50	2.08	5.54	5.11	-	-	-
FocalClick-HR18s-S1 _{CVPR22}	0.03	1.82	2.89	7.29	6.56	13.99	13.39	7.66
FocalClick-HR18s-S2 _{CVPR22}	0.07	1.62	2.66	6.79	5.25	13.29	12.00	6.93
FocalClick-HR32-S2 _{CVPR22}	0.14	1.80	2.36	6.51	5.39	12.40	11.59	6.67
FocalClick-SegFB0-S1 _{CVPR22}	0.01	1.86	3.29	7.60	7.42	13.99	14.01	8.03
FocalClick-SegFB0-S2 _{CVPR22}	0.02	1.66	2.27	6.86	5.49	12.31	11.77	6.73
FocalClick-SegFB3-S2 _{CVPR22}	0.10	1.50	1.92	5.59	4.90	11.20	10.54	5.94
InterFormer-Light _{ICCV23}	0.13 [†]	1.50	3.14	6.34	6.19	12.03	11.27	6.75
InterFormer-Tiny _{ICCV23}	0.23 [†]	1.36	2.53	5.51	5.21	10.84	9.42	5.81
SimpleClick-ViT-B _{ICCV23}	1.26	1.48	1.97	5.62	5.06	11.15	9.93	5.87
SimpleClick-ViT-L _{ICCV23}	3.12	1.40	1.89	4.89	4.81	10.65	9.07	5.45
SimpleClick-ViT-H _{ICCV23}	6.99	1.50	1.75	4.70	4.78	10.56	9.13	5.40
[‡] SAM-ViT-H _{ICCV23}	0.35 [†]	1.88	2.09	7.62	5.19	13.97	10.36	6.85
FocSAM-ViT-H (Ours)	0.39 [†]	1.32	1.47	4.69	4.77	11.14	8.91	5.38

图2