



无人机如何自主侦察？UEAVAD：基于视觉的无人机主动目标探测与导航数据集



视觉语言导航
VLNavigation

关注他

2 人赞同了该文章

赞同 2




分享



微信公众号

视觉语言导航



- 作者：Xinhua Jiang, Tianpeng Liu, Li Liu, Zhen Liu, and Yongxiang Liu
- 单位：国防科技大学电子科学学院
- 论文标题：UEVAVD: A Dataset for Developing UAV's Eye View Active Object Detection
- 论文链接：arxiv.org/pdf/2411.0434...
- 代码链接：github.com/Leo000ooo/UE...

主要贡献

- 论文发布了数据集UEVAVD，旨在促进无人机视角的主动目标检测⁺（AOD）问题的研究。该数据集包含不同环境设置下的多视图成像结果，有助于研究如何更好地利用无人机的自主性和机动性来克服基于无人机的目标检测中的遮挡问题。
- 提出了结合归纳偏置的深度强化学习（DRL）改进方法，称为诱导偏差增强的多步动作预测（IBE-MAP）。通过场景预分解和基于记忆的状态估计，增强了智能体策略的泛化能力。
- 利用CNN和GRU从历史观测序列中提取状态表示，而不是依赖单视图观测。此外，使用Segment Anything Model⁺（SAM）对场景进行预分解，并过滤掉无关信息，从而提高了决策网络的状态表示。
- 引入了上下文马尔可夫决策过程⁺（CMDP）来量化智能体策略在UEVAVD数据集上的零样本泛化（ZSG）能力，并通过实验验证了所提方法的优越性。

研究背景

研究问题

论文主要解决的问题是无人机（UAV）在目标检测中遇到的遮挡问题。

赞同 2

添加评论

分享

喜欢

收藏

申请转载

...



研究难点

该问题的研究难点包括：

- 无人机在视图中无法确定目标身份时的决策问题，
- 如何在移动过程中最小化运动成本以获取理想的观测视角。

相关工作

- **UAV目标检测**
 - **深度学习方法**：近年来，基于深度神经网络（DNN）的方法如Faster-RCNN、YOLO、SSD及其变体逐渐成为UAV目标检测的主流方法。这些方法通过改进网络结构和算法来提高检测性能，但仍然面临遮挡问题的挑战。
 - **遮挡处理**：一些研究通过自适应改进检测模型来应对遮挡问题，例如使用Soft-NMS方法在后期处理中抑制冗余预测帧以减轻遮挡影响。然而，这些方法的抗遮挡能力仍不理想。
- **主动视觉**
 - **室内应用**：主动视觉主要应用于室内机器人领域。Ammirato等人首次使用REINFORCE算法进行主动视觉任务，并发布了用于开发和基准化主动视觉算法的数据集 AVD (Active Vision Dataset)。Han等人使用双深度Q学习网络（DualingDQN）结合优先经验回放解决了主动视觉问题。Fang等人使用自监督表示学习来提高DRL方法的样本效率。
 - **室外应用**：尽管室内环境中有多组主动视觉数据集（如AVD、T-LESS和R3ED），但在无人机视角下的主动目标检测方面缺乏类似的数据集。现有的UAV目标检测数据集（如VisDrone-DET）虽然覆盖了丰富的环境设置和目标，但由于缺乏密集的多视角图像，无法用于研究空地主动目标检测问题。
- **主动目标检测（AOD）**
 - **DRL框架**：AOD利用主动视觉来改善目标检测结果，通过赋予移动传感平台调整视角的能力来更好地识别目标。DRL已成为解决AOD问题的主流框架。Liu等人通过结合目标裁剪到状态表示并设计新的奖励函数来帮助机器人更平滑地接近目标物体。

数据集构建

目标和环境设置



(1) Hatchback



(2) Pickup



(3) Sportscar



(4) Sedan



(5) SUV

知乎 @视觉语言导航

- **目标**：数据集专注于城市和林地地形中的车辆目标。选择了五种类型的车辆目标（Hatchback、Pickup、Sports Car、Sedan、SUV），并在线资源中整合到项目中。为了避免分类器仅通过颜色信息区分目标，标准化了Hatchback、Pickup、Sedan和SUV的颜色和纹理以匹配Sportscar。
- **环境**：为了确保数据集的丰富性和多样性，随机分布目标位置在整个场景中。目标通常放置在建筑物或树木附近，以模拟复杂的背景环境。




采样过程

- 采样点：在每个场景中，无人机在目标区域内的特定采样点均匀分布处观察目标。采样点的坐标表示为 (x_s, y_s, z_s) ，距离目标的距离满足以下条件：

$$\begin{cases} -50 \leq x_s \leq 50, x_s \in \mathbb{Z} \\ -50 \leq y_s \leq 50, y_s \in \mathbb{Z} \\ 60 \leq z_s \leq 100, z_s \in \mathbb{Z} \end{cases}$$

相邻采样点之间的最小距离为10米。

- 图像处理：使用AirSim+插件获取原始RGB图像和整个场景的地面真实分割图像。为了减少计算量，将原始RGB图像裁剪为中心在目标的256×256像素的区域，并从原始图像和分割图像中导出目标的边界框。




数据集概述


UEVAVD Dataset			
Split	Training Set	Test Set (Simple)	Test Set (Hard)
Target	Hatchback, Pickup, Sports Car, Sedan, SUV		
Terrain	Urban		Urban, Woodland
Context ID	01, 02, ..., 20, 31, 32, ..., 50, 61, 62, ..., 80, 91, 92, ..., 110, 120, 121, ..., 140	21, 22, ..., 25, 51, 52, ..., 55, 81, 82, ..., 85, 111, 112, ..., 115, 141, 142, ..., 145	26, 27, ..., 30, 56, 57, ..., 80, 86, 87, ..., 90, 116, 117, ..., 120, 146, 147, ..., 150
Context Number	100	25	25
Image Number	60500	15125	15125
Annotation Number	60500	15125	15125

60500张图像，测试集（简单和困难）各有15125张图像。

- 目标位置分布：目标位置在场景中的分布通过俯视图展示，红色点表示训练上下文，蓝色点或星号表示测试上下文。测试上下文在目标位置分布上更明显地偏离训练上下文，以增加数据集的多样性。



研究方法



问题建模

- POMDP⁺模型**：AOD问题被建模为部分可观测马尔可夫决策过程（POMDP），通常表示为七元组 $\langle \mathcal{S}, \mathcal{A}, \mathcal{O}, T, \Omega, R, \gamma \rangle$ 。其中， $\mathcal{S}$ 是智能体的状态集， $\mathcal{A}$ 是动作集， $\mathcal{O}$ 是观测集， $T(s'|s, a)$ 是状态转移函数， $\Omega(o|s, a)$ 是观测函数， $R(s, a)$ 是奖励函数， γ 是折扣因子。
- 状态表示**：状态 $s \in \mathcal{S}$ 是从无人机的观测中提取的状态表示。动作 $a \in \mathcal{A}$ 包括动作类型（如前进、后退、左转、右转、下降、上升、停止）和动作范围。
- 观测函数**：观测 o 包括无人机视角的航拍图像 I 和目标的边界框 b 。目标的位置在后续帧中可以通过跟踪算法获得。

奖励函数设计

- 奖励函数 $R(s, a)$ 考虑了检测准确性、决策步骤和无人机的移动路径。具体定义如下：

$$R(s, a) = \begin{cases} \xi_1 - \sigma \cdot a_{\text{range}}, & \text{if flag} = 1, \text{ reco} = 1 \\ -\xi_1 - \sigma \cdot a_{\text{range}}, & \text{if flag} = 1, \text{ reco} = 0 \\ -\xi_2 - \sigma \cdot a_{\text{range}}, & \text{if flag} = 0 \end{cases}$$

其中， ξ_1 和 ξ_2 是正的奖励常数， σ 是控制动作范围的系数。

策略优化

- 通过求解以下优化问题来获得智能体的最优观测策略 π^* ：

$$\pi^* = \arg \max_{\pi \in \Pi} E_{s \sim \rho(s)} [r(s)]$$

其中， $\pi(a_t|s_t)$ 表示智能体的策略， Π 是策略集， $\rho(s)$ 是初始状态的分布， $r(s)$ 是在一个回合内的期望回报。

诱导偏差增强的AOD方法


- 论文提出了一种改进的多步动作预测（MAP）方法，称为诱导偏差增强的多步动作预测（IBE-MAP）。该方法利用两种先验知识来增强状态表示：

- 场景预分解**：使用Segment Anything Model (SAM) 对场景进行预分解，过滤掉与目标识别无关的信息。


实验与结果分析

实验设置

- **数据集划分**：UEVAVD数据集被划分为三个部分：训练集、简单测试集和困难测试集。训练集用于训练智能体的策略网络，困难测试集用于测试策略。
- **网络选择**：选择一个在ImageNet上预训练的ResNet18网络作为分类器，并使用未遮挡的多视角图像对其进行微调。
- **基线比较**：比较基线方法包括MAP（Multistep Action Prediction）和Memo-MAP（Memo-MAP是MAP的改进版本，结合了记忆模块来提取状态表示，但不包括场景预分解阶段）。



结果和分析



• 困难测试集上的评估：

- 在困难测试集上，对不同策略的表现进行了比较。结果显示，随机策略由于任意给出动作指令而失败；
- MAP策略成功帮助无人机避开障碍物并获得正确的识别结果，但明显偏离了最优路径；
- IBE-MAP策略引导无人机以更低的移动成本找到更好的视角，并在找到足够识别的视角后做出提前停止决策以提高效率。

• 总体比较：

- 展示了三种AOD方法在回报、识别率和移动距离方面的表现。
- 结果表明，随着训练的进行，所有策略的回报曲线都在上升，表明它们能够帮助智能体以更低的移动成本获得更好的识别结果。
- IBE-MAP方法在测试时具有最明显的泛化能力，其回报值超过了其他两种方法，且泛化差距最小。

TABLE II

THE AGENT’S POLICY PERFORMANCE VERSUS CLASSIFICATION THRESHOLD

	<i>thre</i> =0.2	<i>thre</i> =0.4	<i>thre</i> =0.6	<i>thre</i> =0.8
Return	-0.059±0.006	-0.072±0.021	-0.102±0.011	-0.178±0.011
Accuracy	0.610±0.015	0.602±0.022	0.605±0.009	0.603±0.015
Path Length	4.065±0.169	4.160±0.171	4.211±0.152	4.505±0.190

TABLE III

THE AGENT’S POLICY PERFORMANCE VERSUS HYPERPARAMETER *C*

	<i>C</i> =0	<i>C</i> =0.02	<i>C</i> =0.04	<i>C</i> =0.06
Return	0.000±0.004	-0.059±0.006	-0.119±0.010	-0.146±0.019
Accuracy	0.616±0.007	0.610±0.015	0.577±0.005	0.575±0.025
Path Length	4.717±0.160	4.065±0.169	3.509±0.104	3.147±0.076

- 分类阈值的影响：
 - 分析了分类阈值对策略性能的影响。结果表明，随着阈值的增加，回报下降，路径长度延长，但对识别准确率的影响较小。
- 动作范围系数的影响：
 - 分析了动作范围系数对策略性能的影响。
 - 结果表明，随着动作范围约束的增加，路径长度缩短，但识别率降低。
 - 存在一个准确性和路径长度之间的权衡，具体设置取决于执行AOD任务时的重要性。

总结

论文发布了一个新的数据集UEVAVD，包含不同地形和遮挡条件下的多视角航拍图像。通过这些观测数据的组合，可以模拟无人机在轨迹上连续观测的过程。

论文提出的IBE-MAP方法通过引入先验知识改进了原始MAP方法，使策略网络能够学习到更好的状态表示，从而提高了智能体在测试环境中的泛化能力。

 微信公众号

 视觉语言导航

发布于 2025-01-25 21:21 · IP 属地湖南

人工智能 具身智能 无人机 (UAV)



理性发言，友善互动



还没有评论，发表第一个评论吧



推荐阅读

YOLO

[论文阅读]无人机视角下目标检测调研

江海寄鱼身

论文分享~~边缘设备上的轻量级无人机物体检测网络

我是个莽夫

无人机目标检测综述（一）——摘要&引言&相关调查和简要...

泽小润

无人机目标检测综述（二）从无人机图像检测目标

泽小润